Indicadores de Ocupabilidad de MINCETUR

14 flujos MapReduce con output

Sergio Sebastian Pezo Jimenez Arbués Enrique Pérez Villegas

Universidad Nacional de Ingeniería
CC531 Análisis en Macrodatos

22 de septiembre de 2026

Contenido

1. Datos y entorno
2. Tipos de consulta: resumen
3. Consultas con dos o más columnas: ítem 1
4. Medidas estadísticas: ítem 2
5. Búsqueda de subtexto: ítem 3
6. Máximo y mínimo agrupados: ítem 4
7. Dos MapReduce enlazados: ítem 5
8. Modelos de clasificación: ítem 6

Dataset

Qué representa una fila

Un mes, un departamento y un nivel clase–categoría; no representa un hotel individual.

- 2019–2025-I, 38 730 filas y 24 columnas.
- 25 departamentos; 2025 contiene seis meses.
- `TT` existe en `ID_CLASE` y `ID_CATEGORIA`.
- `TT/TT` es nuestra abreviatura para ese par de valores; no es otra columna.

Indicadores que originan las preguntas

- **TNOH**: porcentaje de habitaciones disponibles ocupadas.
- **TNOC**: porcentaje de plazas-cama disponibles ocupadas.
- **Arribo**: huésped contado al llegar.
- **Pernoctación**: cada noche que permanece.

Regla de análisis

Filtramos TT/TT cuando buscamos totales departamentales: sumar esos totales junto con sus desagregaciones contaría la misma actividad varias veces.

Columnas

Columna	Significado
FECHA_CORTE	Actualización de la fuente.
ANIO	Año observado.
MES	Mes, de 01 a 12.
ID_CLASE	Código de clase; TT es total.
CLASE	Hotel, hostal, resort, etc.
ID_CATEGORIA	Código de categoría; TT es total.
CATEGORIA	Estrellas o no categorizado.
DEPARTAMENTO	Región de agregación.
ID_UBIGEO	Código geográfico del INEI.
NUMERO_ESTABLECIMIENTOS	Hospedajes incluidos.
NUMERO_HABITACIONES	Habitaciones ofertadas.
NUMERO_PLAZAS_CAMA	Camas disponibles; doble cuenta como dos.

Columna	Significado
PORCENTAJE_TNOH	Ocupación de habitaciones.
PORCENTAJE_TNOC	Ocupación de plazas-cama.
PROMEDIO_PERMANENCIA	Días promedio por huésped.
PROMEDIO_PERMANENCIA_NAC	Permanencia de nacionales.
PROMEDIO_PERMANENCIA_EXT	Permanencia de extranjeros.
TOTAL_ARRIBOS	Huéspedes registrados al llegar.
TOTAL_ARRIBOS_NAC	Arribos nacionales.
TOTAL_ARRIBOS_EXT	Arribos extranjeros.
TOTAL_PERNOCT	Noches ocupadas totales.
TOTAL_PERNOCT_NAC	Noches de nacionales.
TOTAL_PERNOCT_EXT	Noches de extranjeros.
TOTAL_EMPLEO	Personas empleadas en el mes.

TNOH y TNOC son porcentajes; arribos y pernoctaciones son cantidades.

Tipos y preguntas de las 14 consultas

Q	Ítem	Grupo de la práctica	Pregunta
01	1a	Dos o más columnas	¿Cómo evolucionaron los arribos nacionales y extranjeros por año?
02	1b	Dos o más columnas	¿Cuál fue la TNOH media de cada departamento por año?
03	1c	Dos o más columnas	¿Cómo cambian la TNOH y la TNOC según la clase de hospedaje?
04	1d	Dos o más columnas	¿Cuántos empleos existen por cada cien habitaciones en cada departamento y año?
05	1e	Dos o más columnas	¿Qué meses concentran más arribos y pernoctaciones?
06	2	Medidas estadísticas	¿Cuál es la cantidad, media, mediana y desviación de la TNOH?
07	3	Búsqueda de subtexto	¿Qué registros contienen un texto en clase, categoría o departamento?
08	4	Máximo y mínimo agrupados	¿Qué departamentos tuvieron la menor y mayor TNOH media de cada año?
09	5a	Dos MapReduce enlazados	¿Cuánto cambió la TNOH entre 2019 y 2024?
10	5b	Dos MapReduce enlazados	¿Qué porcentaje de arribos fue extranjero en cada periodo?
11	6a	Modelo de clasificación	¿La TNOH es alta o baja según los otros indicadores?
12	6b	Modelo de clasificación	¿La TNOH mensual departamental es alta o baja según los demás indicadores?
13	7a	Modelo de regresión	¿Qué valor continuo de TNOH estiman los indicadores?
14	7b	Modelo de regresión	¿Qué TNOH se estima al controlar los coeficientes con regularización L2?

Q01 — Ítem 1a: arribos por origen

Pregunta

¿Cómo evolucionaron los arribos nacionales y extranjeros por año?

Mapper. Filtra TT/TT y emite `ANIO -> ARRIBOS_NAC,ARRIBOS_EXT`.

Reducer. El shuffle reúne meses y departamentos del mismo año; después suma ambos orígenes por separado.

Output real. `2019 national=54897127 foreign=8264767`

Respuesta. La serie evidencia la caída de 2020 y la recuperación posterior. 2025-I no se compara como un año completo.

Q02 — Ítem 1b: TNOH territorial

Pregunta

¿Cuál fue la TNOH media de cada departamento por año?

Mapper. Emite `ANIO;DEPARTAMENTO -> TNOH,1` para cada fila TT/TT.

Reducer. Suma las tasas y los contadores de cada clave; divide suma entre cantidad de meses.

Output real. `2024;CALLAO mean_tnoh=41.5950 | LORETO=12.9917`

Respuesta. En 2024 Callao tuvo una TNOH media muy superior a Loreto. Es una media mensual no ponderada por habitaciones.

Q03 — Ítem 1c: ocupación por clase

Pregunta

¿Cómo cambian la TNOH y la TNOC según la clase de hospedaje?

Mapper. Conserva `ID_CATEGORIA=TT`, excluye la clase global y emite `ANIO;CLASE -> TNOH,TNOC,1`.

Reducer. Acumula las dos tasas y calcula sus medias para cada año y clase.

Output real. `2024;RESORT mean_tnoh=46.7742 mean_tnoc=48.2812`

Respuesta. Los resorts muestran ocupación alta de habitaciones y camas. Ambas tasas difieren porque una habitación puede alojar varias personas.

Q04 — Ítem 1d: empleo por capacidad

Pregunta

¿Cuántos empleos existen por cada cien habitaciones en cada departamento y año?

Mapper. Filtra TT/TT y emite `ANIO;DEPARTAMENTO -> EMPLEO,HABITACIONES`.

Reducer. Suma primero ambos campos y calcula $100 \times \textit{empleo}/\textit{habitaciones}$.

Output real. `2024;LIMA employment_per_100_rooms=54.3562`

Respuesta. Lima registró 54.36 empleos por cien habitaciones en 2024. La razón no mide productividad ni calidad laboral.

Q05 — Ítem 1e: estacionalidad

Pregunta

¿Qué meses concentran más arribos y pernoctaciones?

Mapper. Emite `MES -> ARRIBOS,PERNOCTACIONES` para cada total TT/TT.

Reducer. Agrupa el mismo mes de todos los años y departamentos y suma ambos indicadores.

Output real. `01 arrivals=33585654 overnight_stays=43787718`

Respuesta. Enero concentra el mayor volumen acumulado; enero–junio incluye 2025-I y tiene un periodo adicional.

Q06 — Ítem 2: medidas estadísticas

Pregunta

¿Cuál es la cantidad, media, mediana y desviación estándar poblacional de la TNOH?

Mapper. Emite cada TNOH TT/TT bajo una clave constante: `TNOH -> valor`.

Reducer. Calcula media y varianza incremental; ordena 1 950 valores para obtener la mediana.

Output real. `count=1950 mean=21.7433 median=21.3400 stddev=7.0679`

Respuesta. La ocupación mensual típica ronda 21 puntos y su desviación es 7.07. Centralizar los valores solo es viable por el tamaño pequeño.

Q07 — Ítem 3: búsqueda de subtexto

Pregunta

¿Qué registros contienen un texto en clase, categoría o departamento?

Mapper. Compara el término en minúsculas con los tres campos y emite `OFFSET -> FILA` si coincide.

Reducer. No se utiliza Reducer: cada coincidencia ya constituye una respuesta final.

Output real. `matches=11525 | 2022;06;HOTEL;1 ESTRELLA;AMAZONAS;...`

Respuesta. La búsqueda literal encontró 11 525 filas con "hotel". No reconoce sinónimos ni normaliza acentos.

Q08 — Ítem 4: máximo y mínimo

Pregunta

¿Qué departamentos tuvieron la menor y mayor TNOH media de cada año?

Mapper. Emite `ANIO -> DEPARTAMENTO,TNOH` para las filas TT/TT.

Reducer. Calcula la media de cada departamento dentro del año y selecciona mínimo y máximo.

Output real. `2024 min=LORETO:12.9917 max=CALLAO:41.5950`

Respuesta. Loreto y Callao delimitan los extremos de 2024. Los dos cálculos ocurren dentro de un solo Reducer.

Q09 — Ítem 5a: dos MapReduce enlazados

Pregunta

¿Cuántos puntos porcentuales cambió la TNOH media entre 2019 y 2024?

Job 1: agregación

Mapper. Filtra TT/TT de ambos años y emite `ANIO;DEP -> TNOH,1`.

Reducer. Calcula la TNOH media de cada año y departamento.

Job 2: comparación

Mapper. Lee la salida anterior y emite `DEP -> ANIO,MEDIA`.

Reducer. Une las dos medias y calcula $media_{2024} - media_{2019}$.

Output real. `APURIMAC change_pp=-18.7325 | UCAYALI=5.0442`

Respuesta. Apurímac tuvo la mayor caída y Ucayali el mayor aumento; el cambio no demuestra causalidad.

Q10 — Ítem 5b: dos MapReduce enlazados

Pregunta

¿Qué porcentaje de los arribos fue extranjero en cada departamento y periodo?

Job 1: agregación

Mapper. Calcula la cuota mensual y emite departamento, periodo, año y mes.

Reducer. Consolida una participación extranjera por mes.

Job 2: comparación

Mapper. Lee esa salida y reagrupa por `DEPARTAMENTO;PERIODO`.

Reducer. Promedia las participaciones mensuales de cada periodo.

Output real. `CUSCO PRE=63.3747 IMPACT=20.5234 RECOVERY=58.3507`

Respuesta. Cusco cayó durante 2020–2021 y luego se recuperó. Es una media mensual no ponderada por arribos.

Q11 — Ítem 6a: clasificación Naive Bayes

Pregunta

¿La TNOH mensual departamental es alta o baja según los demás indicadores?

Mapper. Emite bajo `MODEL` el año, la TNOH objetivo y siete características; filtra TT/TT.

Reducer. Con 2019–2023 fija la mediana, entrena Gaussian Naive Bayes y evalúa 2024 y 2025-I.

Output real. `TEST_2024 accuracy=0.703333 recall=0.286885 f1=0.440252`

Respuesta. El recall bajo indica que el modelo omite muchos casos de ocupación alta; funciona como línea base probabilística.

Q12 — Ítem 6b: clasificación logística

Pregunta

¿La TNOH mensual departamental es alta o baja según los demás indicadores?

Mapper. Emite exactamente los mismos ejemplos y características que Q11.

Reducer. Estandariza solo con entrenamiento, ajusta 200 iteraciones y calcula las métricas.

Output real. `TEST_2024 accuracy=0.840000 recall=0.754098 f1=0.793103`

Respuesta. La regresión logística mejoró claramente recall y F1 frente a Naive Bayes con los mismos datos.

Ítem 6 — Comparación de clasificación

Periodo	Modelo	Accuracy	Prec.	Recall	F1	Log loss
2024	Naive Bayes	0.7033	0.9459	0.2869	0.4403	0.9470
2024	Logística	0.8400	0.8364	0.7541	0.7931	0.4988
2025-I	Naive Bayes	0.7267	1.0000	0.3051	0.4675	0.8545
2025-I	Logística	0.8000	0.8718	0.5763	0.6939	0.4748

Lectura principal

Naive Bayes fue muy preciso cuando predijo ocupación alta, pero detectó pocos casos altos. La logística obtuvo mejor equilibrio, mayor F1 y menor log loss en ambos periodos.

Q13 — Ítem 7a: regresión lineal

Pregunta

¿Qué valor continuo de TNOH puede estimarse usando los demás indicadores?

Mapper. Emite `MODEL -> ANIO,TNOH,7 características` para cada fila TT/TT.

Reducer. Estandariza con 2019–2023, ajusta $\lambda = 0$ y calcula MAE, RMSE y R^2.

Output real. `TEST_2024 mae=3.192221 rmse=4.092002 r_squared=0.643537`

Respuesta. El MAE fue 3.19 puntos y el modelo explicó 64.35 % de la variación de 2024.

Q14 — Ítem 7b: regresión Ridge

Pregunta

¿Qué TNOH se estima al controlar el tamaño de los coeficientes con regularización L2?

Mapper. Emite los mismos ejemplos, variables y periodos que Q13.

Reducer. Ajusta Ridge con penalización L2, $\lambda = 1$, sin penalizar el intercepto.

Output real. `VALIDATION_2025_H1 rmse=3.879584 r_squared=0.670320`

Respuesta. Ridge mejoró ligeramente RMSE y R^2; solo se evaluó un valor de λ.

Ítem 7 — Comparación de regresión

Periodo	Modelo	MAE	RMSE	R^2
2024	Lineal	3.1922	4.0920	0.6435
2024	Ridge	3.1943	4.0726	0.6469
2025-I	Lineal	3.0208	3.9273	0.6622
2025-I	Ridge	3.0133	3.8796	0.6703

Lectura principal

Ridge redujo ligeramente los errores grandes medidos por RMSE y aumentó R^2. La diferencia es pequeña: no basta para declarar una superioridad fuerte ni un λ óptimo.

Conclusiones: de preguntas a respuestas

Qué respondimos

- Q01–Q05: evolución, territorio, clase, capacidad y estacionalidad.
- Q06–Q08: distribución, búsqueda y extremos.
- Q09–Q10: cambio temporal y participación extranjera con dos jobs.
- Q11–Q12: la logística logró mejor equilibrio; F1=0.7931 en 2024.
- Q13–Q14: Ridge mejoró ligeramente; RMSE=3.8796 en 2025-I.

Hasta dónde llegan las respuestas

No prueban causalidad. 2025 tiene seis meses. Algunos promedios no ponderan capacidad. Un nodo valida el pipeline, no escalabilidad. Los modelos caben en un reducer por el volumen pequeño.

Referencias I

- Ministerio de Comercio Exterior y Turismo, "Indicadores de Ocupabilidad," Plataforma Nacional de Datos Abiertos, 2021.
- Ministerio de Economía y Finanzas, "Ficha Técnica Simplificada para proyectos turísticos," 2021.
- J. Dean y S. Ghemawat, "MapReduce: Simplified Data Processing on Large Clusters," *Communications of the ACM*, vol. 51, no. 1, pp. 107–113, 2008.
- M. Mariani y R. Baggio, "Big data and analytics in hospitality and tourism: A systematic literature review," *International Journal of Contemporary Hospitality Management*, vol. 34, no. 1, pp. 231–278, 2022.

Preguntas y demostración