

# Análisis de los Indicadores de Ocupabilidad de MINCETUR

Hadoop MapReduce, clasificación y regresión

Sergio Sebastian Pezo Jimenez    Arbués Enrique Pérez Villegas

Universidad Nacional de Ingeniería  
CC531 Análisis en Macrodatos

22 de septiembre de 2026



- MINCETUR publica los indicadores en la Plataforma Nacional de Datos Abiertos.
- La encuesta registra capacidad y uso de hospedajes a nivel nacional y regional.
- El MEF usa estos indicadores como referencia para estimar demanda turística.

## Lo encontrado

Los estudios previos se concentran en una región y usan métodos estadísticos clásicos.

Fuentes: MINCETUR (2021), MEF (2021), Taípe y Laura (2021), Ñahuincopa y Rojas (2022).

# Columnas del dataset

## Identificación y dimensiones

- $FECHA_CORTE$  : fecha de actualización.
- ANIO, MES: periodo observado.
- $ID_C LASE$ , CLASE :  
tipo de establecimiento.
- $ID_C ATEGORIA$ , CATEGORIA : categoría.
- DEPARTAMENTO,  $ID_U BIGEO$  : ubicación.

## Capacidad

- $NUMERO_E STABLECIMIENTOS$  :  
locales reportados.
- $NUMERO_H ABITACIONES$  :  
habitaciones disponibles.
- $NUMERO_P LAZAS_C AMA$  : camas ofertadas.

## Indicadores

- $PORCENTAJE_T NOH$  :  
ocupación neta de habitaciones.
- $PORCENTAJE_T NOC$  :  
ocupación neta de camas.
- $PROMEDIO_P ERMANENCIA$  :  
día promedio de estadía.
- $PROMEDIO_P ERMANENCIA_{NAC/EXT}$  :  
estadía nacional o extranjera.

## Movimientos y empleo

- $TOTAL_A RRIPOS$ ,
- $TOTAL_P ERNOCT$ ,
- $TOTAL_E MPLEO$  :  
personas empleadas reportadas.

**Siglas:** TNOH es ocupación neta de habitaciones; TNOC, de camas. TT/TT

---

|                     |             |
|---------------------|-------------|
| Periodo             | 2019–2025-I |
| Registros           | 38 730      |
| Columnas            | 24 columnas |
| Departamentos       | 25          |
| Archivos originales | 7           |

---

## Datos principales

- establecimientos, habitaciones y plazas-cama;
- TNOH, TNOC y permanencia;
- arribos, pernoctaciones y empleo.

Se conservaron intactos los CSV originales. El archivo canónico usa UTF-8, punto decimal y una cabecera común.

## Ítem 1: consulta con dos o más campos.

- **Pregunta:** ¿cómo evolucionaron los arribos nacionales y extranjeros por año?
- **Campos:** año, arribos nacionales y arribos extranjeros.
- **Resultado:** nacionales: 54,9 millones en 2019 y 34,6 millones en 2020.

### Ítem 1: consulta con dos o más campos.

- **Pregunta:** ¿cuál fue la TNOH promedio de cada departamento por año?
- TNOH significa ocupación neta de habitaciones.
- **Resultado:** Callao llegó a 41,5950 en 2024; Loreto, a 12,9917.

### Ítem 1: consulta con dos o más campos.

- **Pregunta:** ¿cómo cambian TNOH y TNOC según la clase?
- TNOC significa ocupación neta de camas.
- **Resultado:** en 2024, Resort obtuvo TNOH 46,7742 y TNOC 48,2812.

### Ítem 1: consulta con dos o más campos.

- **Pregunta:** ¿cuántos empleos se reportan por cada 100 habitaciones?
- **Campos:** año, departamento, empleo y habitaciones.
- **Resultado:** Lima obtuvo 54,3562 empleos por cada 100 habitaciones en 2024.

### Ítem 1: consulta con dos o más campos.

- **Pregunta:** ¿qué meses concentran más arribos y pernoctaciones?
- **Campos:** mes, arribos y pernoctaciones.
- **Resultado:** enero y febrero tuvieron los mayores acumulados.

### Ítem 2: promedio, mediana y desviación.

- **Pregunta:** ¿cuál es el nivel central y la dispersión de la ocupación?
- **Resultado:** 1 950 valores; media 21,7433; mediana 21,3400; desviación 7,0679.
- La mediana divide la mitad inferior y superior de los valores.

### Ítem 3: búsqueda de subtexto.

- **Pregunta:** ¿qué registros contienen la palabra hotel?
- **Campos:** clase, categoría y departamento.
- **Resultado:** 11 525 coincidencias con el registro completo.

### Ítem 4: mayor y menor valor agrupado.

- **Pregunta:** ¿qué departamento tuvo la menor y mayor TNOH media por año?
- **Resultado 2024:** Loreto fue el mínimo (12,9917) y Callao el máximo (41,5950).

### Ítem 5: dos MapReduce enlazados.

- Job 1 calcula la TNOH promedio por año y departamento.
- Job 2 une 2019 con 2024 y calcula la diferencia.
- **Resultado:** Apurímac tuvo la mayor caída: -18,7325 puntos porcentuales.

### Ítem 5: dos MapReduce enlazados.

- **Pregunta:** ¿cómo cambió la proporción de arribos extranjeros?
- **Resultado:** 63,3747 % antes de la pandemia; 20,5234 % durante el impacto; 58,3507 % en recuperación.

## Ítem 6: modelo de clasificación.

- **Pregunta:** ¿la ocupación mensual es alta o baja?
- Alta significa TNOH mayor o igual a la mediana del entrenamiento.
- **F1:** 0,4403 en 2024 y 0,4675 en 2025-I.

### Ítem 6: modelo de clasificación.

- Se respondió la misma pregunta con las mismas variables.
- **F1:** 0,7931 en 2024 y 0,6939 en 2025-I.
- Fue el clasificador más equilibrado.

### Ítem 7: modelo de regresión.

- **Pregunta:** ¿qué TNOH se predice usando los demás indicadores?
- Entrenamiento: 2019–2023; evaluación: 2024 y 2025-I.
- **Resultado 2024:** MAE 3,1922; RMSE 4,0920; R cuadrado 0,6435.

### Ítem 7: modelo de regresión.

- **Pregunta:** ¿la regularización mejora la predicción de TNOH?
- **Resultado 2025-I:** MAE 3,0133; RMSE 3,8796; R cuadrado 0,6703.
- La mejora frente al modelo lineal fue pequeña.

- Se logró unificar siete CSV sin modificar los originales.
- Las catorce consultas dejaron salida real y un JAR reproducible.
- La investigación previa ayudó a normalizar el esquema, evitar doble conteo y elegir una evaluación temporal.
- La regresión logística obtuvo el mejor F1 y ridge mejoró ligeramente el RMSE.

## Límites

2025 contiene solo seis meses. El clúster tuvo un nodo y el dataset no representa macrodatos por volumen.

# Referencias I



Ministerio de Comercio Exterior y Turismo, “Indicadores de Ocupabilidad,” Plataforma Nacional de Datos Abiertos, 2021. [En línea]. Disponible en: <https://www.datosabiertos.gob.pe/dataset/indicadores-de-ocupabilidad-ministerio-de-comercio-exterior-y-turismo->



Ministerio de Economía y Finanzas, “Ficha Técnica Simplificada para proyectos de inversión pública en servicios turísticos,” Lima, Perú, 2021.



H. Taipe Pari y J. G. Laura Huamán, “Desestacionalización de la serie de tiempo llegada mensual de turistas y la oferta de hospedaje en la región Huancavelica, periodo 2003–2019,” Universidad Nacional de Huancavelica, 2021.



J. Dean y S. Ghemawat, “MapReduce: Simplified Data Processing on Large Clusters,” *Communications of the ACM*, vol. 51, no. 1, pp. 107–113, 2008, doi: 10.1145/1327452.1327492.



A. P. Viteri Gonzales y J. A. Beltrán García, “Solución de big data para el análisis de datos abiertos de MINSA y CENARES bajo Apache Hadoop y Microsoft Azure,” Universidad Privada Antenor Orrego, 2023.



M. Mariani y R. Baggio, "Big data and analytics in hospitality and tourism: A systematic literature review," *International Journal of Contemporary Hospitality Management*, vol. 34, no. 1, pp. 231–278, 2022, doi: 10.1108/ijchm-03-2021-0301.