

Indicadores de Ocupabilidad de MINCETUR

14 flujos MapReduce con output real

Sergio Sebastian Pezo Jimenez Arbués Enrique Pérez Villegas

Universidad Nacional de Ingeniería
CC531 Análisis en Macrodatos

22 de septiembre de 2026

Contenido

- 1 Datos y entorno
- 2 Consultas MapReduce
- 3 Estadística y comparación
- 4 Modelos
- 5 Cierre
- 6 Referencias

Dataset consolidado

- Periodo 2019–2025-I.
- 38 730 registros.
- 24 columnas.
- 25 departamentos.
- El cambio de esquema fue normalizado.
- Se usa TT/TT para evitar doble conteo.



Name	Address	Phone	Email	Website	Summary
...	...	...	...	...	...

Entorno Hadoop 3.5.0

- Docker Compose en un nodo.
- HDFS conserva entrada y salidas.
- YARN ejecuta los JAR.
- La división temporal evita fuga futura.



Name	Address	Phone	Email	Website	Summary
...	...	...	...	...	...

Q01 — arribos por origen

Mapper

Emite año como clave y arribos nacionales/extranjeros como valor; filtra TT/TT.

Reducer

Suma ambos orígenes para todas las filas del mismo año.

Output real

```
2019 national=54897127 foreign=8264767
```

Decisión: comparar por año revela la caída de 2020 sin mezclar el semestre 2025.

Q02 — TNOH por departamento

Mapper

Emite año-departamento y el par TNOH,1 para cada fila TT/TT.

Reducer

Acumula suma y conteo; calcula la TNOH media por territorio.

Output real

2024;CALLAO mean_tnoh=41.5950 | LORETO=12.9917

Decisión: la clave territorial permite comparar departamentos con la misma definición.

Q03 — TNOH y TNOC por clase

Mapper

Emite año-clase con TNOH, TNOC y contador; usa categoría total y excluye clase TT.

Reducer

Promedia ambos indicadores para cada clase de hospedaje.

Output real

```
2024;RESORT mean_tnoh=46.7742 mean_tnoc=48.2812
```

Decisión: separar clases muestra patrones que un total nacional ocultaría.

Q04 — empleo por capacidad

Mapper

Emite año-departamento con empleo y habitaciones en filas TT/TT.

Reducer

Suma ambos campos y calcula $100 \times \text{empleo} / \text{habitaciones}$.

Output real

```
2024;LIMA employment_per_100_rooms=54.3562
```

Decisión: la razón normaliza capacidades distintas y hace comparable cada territorio.

Q05 — estacionalidad mensual

Mapper

Emite mes como clave y arribos/pernoctaciones como valores.

Reducer

Suma ambos indicadores para todas las observaciones del mismo mes.

Output real

```
01 arrivals=33585654 overnight_stays=43787718
```

Decisión: agrupar por mes muestra estacionalidad; enero–junio tiene un año adicional.

Mapper

Emite todos los valores TNOH TT/TT bajo la clave común TNOH.

Reducer

Ordena 1 950 valores y calcula media, mediana y desviación poblacional.

Output real

```
count=1950 mean=21.7433 median=21.3400 stddev=7.0679
```

Decisión: una clave global sirve aquí porque el volumen es pequeño; no escala a cuantiles masivos.

Mapper

Compara “hotel” con clase, categoría y departamento; emite offset y fila coincidente.

Reducer

No se utiliza Reducer: cada coincidencia ya constituye el resultado final.

Output real

```
matches=11525 | 2022;06;HOTEL;1 ESTRELLA;AMAZONAS;...
```

Decisión: un job map-only evita una etapa de agregación que no aporta valor.

Q08 — extremos de TNOH

Mapper

Emite año y el par departamento,TNOH para filas TT/TT.

Reducer

Calcula medias departamentales dentro del año y selecciona mínimo y máximo.

Output real

2024 min=LORETO:12.9917 max=CALLAO:41.5950

Decisión: resolver medias y extremos juntos evita un segundo job para este dataset.

Mapper

Job 1 emite año-departamento,TNOH; Job 2 reagrupa promedios por departamento.

Reducer

Job 1 calcula medias; Job 2 une 2019/2024 y resta puntos porcentuales.

Output real

APURIMAC change_pp=-18.7325 | UCAYALI=5.0442

Decisión: dos jobs separan agregación y comparación temporal, haciendo verificable cada etapa.

Q10 — participación extranjera

Mapper

Job 1 emite departamento-mes con arribos; Job 2 cambia la clave a departamento-periodo.

Reducer

Calcula porcentaje mensual y después su media por periodo analítico.

Output real

CUSCO PRE=63.3747 IMPACT=20.5234 RECOVERY=58.3507

Decisión: los periodos distinguen choque y recuperación; la media no pondera por arribos.

Q11 — Gaussian Naive Bayes

Mapper

Emite cada ejemplo TT/TT codificado bajo la clave común MODEL.

Reducer

Separa años, fija la mediana, entrena Gaussian NB y calcula métricas.

Output real

TEST_2024 accuracy=0.703333 recall=0.286885 f1=0.440252

Decisión: se eligió como línea base probabilística; su bajo recall revela la limitación de independencia.

Q12 — regresión logística

Mapper

Emite las mismas variables y partición temporal bajo la clave MODEL.

Reducer

Estandariza con entrenamiento, ajusta 200 iteraciones y evalúa probabilidades.

Output real

TEST_2024 accuracy=0.840000 recall=0.754098 f1=0.793103

Decisión: se eligió por interpretabilidad y mejor equilibrio entre precisión y recall.

Q13 — regresión lineal

Mapper

Emite año, TNOH objetivo y vector de características bajo MODEL.

Reducer

Entrena con 2019–2023 y calcula MAE, RMSE y R^2 en años posteriores.

Output real

TEST_2024 mae=3.192221 rmse=4.092002 r_squared=0.643537

Decisión: da una referencia interpretable para predecir el valor continuo de TNOH.

Q14 — regresión ridge

Mapper

Emite exactamente los mismos ejemplos que Q13 para una comparación justa.

Reducer

Ajusta regresión con penalización L2, $\lambda = 1$, y calcula las mismas métricas.

Output real

```
VALIDATION_2025_H1 mae=3.013257 rmse=3.879584 r_squared=0.670320
```

Decisión: Ridge controla coeficientes correlacionados; la mejora observada es pequeña.

Resultados

- Q01–Q05: consultas con múltiples campos.
- Q06: estadística descriptiva.
- Q07: búsqueda de subtexto.
- Q08: extremos agrupados.
- Q09–Q10: dos MapReduce enlazados.
- Q11–Q12: clasificación.
- Q13–Q14: regresión.
- Logística: F1 0,7931 en 2024.
- Ridge: RMSE 3,8796 en 2025-I.

Límites

2025 tiene seis meses.
El clúster usa un nodo.
Algunos promedios no ponderan capacidad.
Los modelos se entrenan en un reducer por el volumen pequeño.

Referencias I



Ministerio de Comercio Exterior y Turismo, “Indicadores de Ocupabilidad,” Plataforma Nacional de Datos Abiertos, 2021.



Ministerio de Economía y Finanzas, “Ficha Técnica Simplificada para proyectos turísticos,” 2021.



J. Dean y S. Ghemawat, “MapReduce: Simplified Data Processing on Large Clusters,” *Communications of the ACM*, vol. 51, no. 1, pp. 107–113, 2008.



M. Mariani y R. Baggio, “Big data and analytics in hospitality and tourism: A systematic literature review,” *International Journal of Contemporary Hospitality Management*, vol. 34, no. 1, pp. 231–278, 2022.

Preguntas y demostración