

Indicadores de Ocupabilidad de MINCETUR

14 flujos MapReduce con output

Sergio Sebastian Pezo Jimenez Arbués Enrique Pérez Villegas

Universidad Nacional de Ingeniería
CC531 Análisis en Macrodatos

22 de septiembre de 2026

Contenido

- 1 Datos y entorno
- 2 Tipos de consulta: resumen
- 3 Agregación descriptiva: Q01–Q05
- 4 Estadística descriptiva: Q06
- 5 Búsqueda de texto: Q07
- 6 Extremos agrupados: Q08
- 7 MapReduce encadenado: Q09–Q10
- 8 Clasificación supervisada: Q11–Q12

Cómo leer el dataset antes de preguntar

Qué representa una fila

Un mes, un departamento y un nivel clase-categoría; no representa un hotel individual.

- 2019–2025-I, 38 730 filas y 24 columnas.
- 25 departamentos; 2025 contiene seis meses.
- TT/TT: total departamental de todas las clases y categorías.

Indicadores que originan las preguntas

- **TNOH**: porcentaje de habitaciones disponibles ocupadas.
- **TNOC**: porcentaje de plazas-cama disponibles ocupadas.
- **Arribo**: huésped contado al llegar.
- **Pernoctación**: cada noche que permanece.

Regla de análisis

Filtramos TT/TT cuando buscamos totales departamentales: sumar esos totales junto con sus desagregaciones contaría la misma actividad varias veces.

Entorno: CSV canónico en HDFS; YARN ejecuta los JAR sobre Hadoop 3.5.0 en un nodo. Esto valida el flujo, no el escalamiento horizontal.

Tipos y preguntas de las 14 consultas

Q	Tipo de pregunta	Pregunta
01	Agregación temporal	¿Cómo evolucionaron los arribos nacionales y extranjeros por año?
02	Promedio territorial	¿Cuál fue la TNOH media de cada departamento por año?
03	Comparación de grupos	¿Cómo cambian la TNOH y la TNOC según la clase de hospedaje?
04	Razón de sumas	¿Cuántos empleos existen por cada cien habitaciones en cada departamento y año?
05	Agregación estacional	¿Qué meses concentran más arribos y pernoctaciones?
06	Estadística descriptiva	¿Cuál es la cantidad, media, mediana y desviación de la TNOH?
07	Búsqueda de texto	¿Qué registros contienen un texto en clase, categoría o departamento?
08	Extremos agrupados	¿Qué departamentos tuvieron la menor y mayor TNOH media de cada año?
09	Comparación encadenada	¿Cuánto cambió la TNOH entre 2019 y 2024?
10	Agregación encadenada	¿Qué porcentaje de arribos fue extranjero en cada periodo?
11	Clasificación probabilística	¿La TNOH es alta o baja según los otros indicadores?
12	Clasificación lineal	¿La TNOH mensual departamental es alta o baja según los demás indicadores?
13	Regresión lineal	¿Qué valor continuo de TNOH estiman los indicadores?
14	Regresión regularizada	¿Qué TNOH se estima al controlar los coeficientes con regularización L2?

Pregunta

¿Cómo evolucionaron los arribos nacionales y extranjeros por año?

Mapper. Filtra TT/TT y emite ANIO -> ARRIBOS_NAC,ARRIBOS_EXT.

Reducer. El shuffle reúne meses y departamentos del mismo año; después suma ambos orígenes por separado.

Output real. 2019 national=54897127 foreign=8264767

Respuesta. La serie evidencia la caída de 2020 y la recuperación posterior. 2025-I no se compara como un año completo.

Pregunta

¿Cuál fue la TNOH media de cada departamento por año?

Mapper. Emite ANIO;DEPARTAMENTO -> TNOH,1 para cada fila TT/TT.

Reducer. Suma las tasas y los contadores de cada clave; divide suma entre cantidad de meses.

Output real. 2024;CALLAO mean_tnoh=41.5950 | LORETO=12.9917

Respuesta. En 2024 Callao tuvo una TNOH media muy superior a Loreto. Es una media mensual no ponderada por habitaciones.

Pregunta

¿Cómo cambian la TNOH y la TNOC según la clase de hospedaje?

Mapper. Conserva ID_CATEGORIA=TT, excluye la clase global y emite ANIO;CLASE -> TNOH,TNOC,1.

Reducer. Acumula las dos tasas y calcula sus medias para cada año y clase.

Output real. 2024;RESORT mean_tnoh=46.7742 mean_tnoc=48.2812

Respuesta. Los resorts muestran ocupación alta de habitaciones y camas. Ambas tasas difieren porque una habitación puede alojar varias personas.

Pregunta

¿Cuántos empleos existen por cada cien habitaciones en cada departamento y año?

Mapper. Filtra TT/TT y emite ANIO;DEPARTAMENTO -> EMPLEO,HABITACIONES.

Reducer. Suma primero ambos campos y calcula $100 \times \text{empleo} / \text{habitaciones}$.

Output real. 2024;LIMA employment_per_100_rooms=54.3562

Respuesta. Lima registró 54.36 empleos por cien habitaciones en 2024. La razón no mide productividad ni calidad laboral.

Pregunta

¿Qué meses concentran más arribos y pernoctaciones?

Mapper. Emite MES -> ARRIBOS,PERNOCTACIONES para cada total TT/TT.

Reducer. Agrupa el mismo mes de todos los años y departamentos y suma ambos indicadores.

Output real. 01 arrivals=33585654 overnight_stays=43787718

Respuesta. Enero concentra el mayor volumen acumulado; enero–junio incluye 2025-I y tiene un periodo adicional.

Pregunta

¿Cuál es la cantidad, media, mediana y desviación estándar poblacional de la TNOH?

Mapper. Emite cada TNOH TT/TT bajo una clave constante: TNOH -> valor.

Reducer. Calcula media y varianza incremental; ordena 1 950 valores para obtener la mediana.

Output real. count=1950 mean=21.7433 median=21.3400 stddev=7.0679

Respuesta. La ocupación mensual típica ronda 21 puntos y su desviación es 7.07. Centralizar los valores solo es viable por el tamaño pequeño.

Pregunta

¿Qué registros contienen un texto en clase, categoría o departamento?

Mapper. Compara el término en minúsculas con los tres campos y emite `OFFSET` -> `FILA` si coincide.

Reducer. No se utiliza Reducer: cada coincidencia ya constituye una respuesta final.

Output real. `matches=11525 | 2022;06;HOTEL;1 ESTRELLA;AMAZONAS;...`

Respuesta. La búsqueda literal encontró 11 525 filas con “hotel”. No reconoce sinónimos ni normaliza acentos.

Pregunta

¿Qué departamentos tuvieron la menor y mayor TNOH media de cada año?

Mapper. Emite `ANIO -> DEPARTAMENTO,TNOH` para las filas `TT/TT`.

Reducer. Calcula la media de cada departamento dentro del año y selecciona mínimo y máximo.

Output real. 2024 min=LORETO:12.9917 max=CALLAO:41.5950

Respuesta. Loreto y Callao delimitan los extremos de 2024. Los dos cálculos ocurren dentro de un solo Reducer.

Pregunta

¿Cuántos puntos porcentuales cambió la TNOH media entre 2019 y 2024?

Job 1: agregación

Mapper. Filtra TT/TT de ambos años y emite ANIO;DEP -> TNOH,1.

Reducer. Calcula la TNOH media de cada año y departamento.

Output real. APURIMAC $\text{change_pp} = -18.7325$ | UCAYALI $= 5.0442$

Job 2: comparación

Mapper. Lee la salida anterior y emite DEP -> ANIO,MEDIA.

Reducer. Une las dos medias y calcula $\text{media}_{2024} - \text{media}_{2019}$.

Respuesta. Apurímac tuvo la mayor caída y Ucayali el mayor aumento; el cambio no demuestra causalidad.

Q10 — Participación extranjera con dos jobs

Pregunta

¿Qué porcentaje de los arribos fue extranjero en cada departamento y periodo?

Job 1: agregación

Mapper. Calcula la cuota mensual y emite departamento, periodo, año y mes.

Reducer. Consolida una participación extranjera por mes.

Output real. CUSCO PRE=63.3747 IMPACT=20.5234 RECOVERY=58.3507

Respuesta. Cusco cayó durante 2020–2021 y luego se recuperó. Es una media mensual no ponderada por arribos.

Job 2: comparación

Mapper. Lee esa salida y reagrupa por DEPARTAMENTO;PERIODO.

Reducer. Promedia las participaciones mensuales de cada periodo.

Pregunta

¿La TNOH mensual departamental es alta o baja según los demás indicadores?

Mapper. Emite bajo MODEL el año, la TNOH objetivo y siete características; filtra TT/TT.

Reducer. Con 2019–2023 fija la mediana, entrena Gaussian Naive Bayes y evalúa 2024 y 2025-I.

Output real. TEST_2024 accuracy=0.703333 recall=0.286885 f1=0.440252

Respuesta. El recall bajo indica que el modelo omite muchos casos de ocupación alta; funciona como línea base probabilística.

Pregunta

¿La TNOH mensual departamental es alta o baja según los demás indicadores?

Mapper. Emite exactamente los mismos ejemplos y características que Q11.

Reducer. Estandariza solo con entrenamiento, ajusta 200 iteraciones y calcula las métricas.

Output real. TEST_2024 accuracy=0.840000 recall=0.754098 f1=0.793103

Respuesta. La regresión logística mejoró claramente recall y F1 frente a Naive Bayes con los mismos datos.

Pregunta

¿Qué valor continuo de TNOH puede estimarse usando los demás indicadores?

Mapper. Emite MODEL -> ANIO,TNOH,7 características para cada fila TT/TT.

Reducer. Estandariza con 2019–2023, ajusta $\lambda = 0$ y calcula MAE, RMSE y R^2 .

Output real. TEST_2024 mae=3.192221 rmse=4.092002 r_squared=0.643537

Respuesta. El MAE fue 3.19 puntos y el modelo explicó 64.35 % de la variación de 2024.

Pregunta

¿Qué TNOH se estima al controlar el tamaño de los coeficientes con regularización L2?

Mapper. Emite los mismos ejemplos, variables y periodos que Q13.

Reducer. Ajusta Ridge con penalización L2, $\lambda = 1$, sin penalizar el intercepto.

Output real. VALIDATION_2025_H1 rmse=3.879584 r_squared=0.670320

Respuesta. Ridge mejoró ligeramente RMSE y R^2 ; solo se evaluó un valor de λ .

Conclusiones: de preguntas a respuestas

Qué respondimos

- Q01–Q05: evolución, territorio, clase, capacidad y estacionalidad.
- Q06–Q08: distribución, búsqueda y extremos.
- Q09–Q10: cambio temporal y participación extranjera con dos jobs.
- Q11–Q12: la logística logró mejor equilibrio; $F1=0.7931$ en 2024.
- Q13–Q14: Ridge mejoró ligeramente; $RMSE=3.8796$ en 2025-I.

Hasta dónde llegan las respuestas

No prueban causalidad. 2025 tiene seis meses. Algunos promedios no ponderan capacidad. Un nodo valida el pipeline, no escalabilidad. Los modelos caben en un reducir por el volumen pequeño.

Referencias I



Ministerio de Comercio Exterior y Turismo, “Indicadores de Ocupabilidad,” Plataforma Nacional de Datos Abiertos, 2021.



Ministerio de Economía y Finanzas, “Ficha Técnica Simplificada para proyectos turísticos,” 2021.



J. Dean y S. Ghemawat, “MapReduce: Simplified Data Processing on Large Clusters,” *Communications of the ACM*, vol. 51, no. 1, pp. 107–113, 2008.



M. Mariani y R. Baggio, “Big data and analytics in hospitality and tourism: A systematic literature review,” *International Journal of Contemporary Hospitality Management*, vol. 34, no. 1, pp. 231–278, 2022.

Preguntas y demostración