

Escuela de Ciencia de la Computación

Laboratorio 01

CC531 A Análisis en Macrodatos 2026 - 2

Parte 1: [5pts]

Resolver un ejercicio dejado por el docente, duración 30 min (si el alumno llega después de 10 minutos iniciado ya no se considera esa parte)

Parte 2: [15 pts]

Configurar una instalación de Hadoop con las versiones vistas en clase, Investigar, implementar y exponer un informe y presentación teniendo en cuenta lo siguiente:

- Implementar o usar su VM de un nodo para correr los programas elaborados
- Buscar una base de datos de la Plataforma Nacional de Datos Abiertos (PNDA) relacionado a **ALIMENTACIÓN Y NUTRICIÓN o TURISMO**, coordinar para que no se repitan Dataset entre los grupos.
- Tanto en el informe como en la presentación: o Referenciar la base de datos usada.
 1. Referencias investigaciones anteriores realizadas a la base datos.
 2. Indicar la fuente de dataset y la fecha de publicación, se tomará en cuenta las bases de datos más recientes.
 3. Referenciar artículos que usaron su dataset si lo hubiera hecho.
- Resolver 7 tipos de consultas propuestas sobre MapReduce, para cada consulta hacer su enunciado de la pregunta a la cual responde:
 1. Hacer 5 consultas Map reduce que usen 2 campos (Columnas) o más cada una.
 2. Encontrar el promedio, la media y la desviación de un campo (Columna) a selección.
 3. Hacer búsqueda de un subtexto general que pueda buscar en varios campos de textos y me dé como resultado(s) uno o varios registros completos.
 4. El mayor y el menor valor de un campo o un conjunto de campos (Columnas) agrupados.
 5. Hacer 2 consultas con campos decimales que implique al menos 2 MapReduce. Cada consulta por separado debe tener los 2 Mapreduce enlazados.
 6. Hacer 2 consulta con campos decimales o texto que implique el uso de un modelo de clasificación (investigar)
 7. Hacer 2 consulta con campos decimales que implique el uso de un modelo de Regresión. (investigar)
- Observar el monitor de recursos y colocar en su informe los datos más representativos.
- En el informe y presentación para mantener la organización por cada consulta se debe mencionar:
 1. Especificar el tipo de pregunta o grupo de pregunta.
 2. Mencionar la consulta en el Dataset a la cual responde. Ejem: "Cual es el promedio de marcas usadas..."

3. Explicar la solución e interpretación de los resultados de cada consulta y como dan acceso a la respuesta, indicando las columnas, filas o características que se usan para ello y las partes importantes del código
- Agregar al informe y presentación los inputs y outputs que pudiera tener sus consultas.
 - Durante la exposición se debe mostrar la ejecución del hadoop en una pregunta seleccionada por el docente.
 - Para el caso de las preguntas de Machine learning elaborar una tabla donde se compare las métricas de loss, accuracy y otras medidas propias que elijan para cada modelo.

Entregables:

- Utilizar las plantillas adjuntas en la tarea.
- Códigos con la extensión JAVA y los JAR (obligatorio)
- Informe y presentación (Obligatorio)
- El dataset utilizado.
- Cada miembro del grupo deberá entrega lo antes mencionado en un zip por el aula virtual.

Observaciones importantes:

- Está prohibido que dos o más grupos utilicen el mismo dataset incluso con rango de fechas o sub partes diferentes, de presentarse el caso no se evaluará a ningún de los grupos involucrados.
- El tiempo límite de exposición es de 10 minutos, de pasarse ese tiempo o hacer bulla o distracción en el aula se aplicarán descuento de puntos.
- Todos los entregables deben presentarse como máximo hasta la fecha establecida en el aula virtual. No se darán plazo adicional de entrega.
- De no presentarse todo entregable calificado como obligatorio, dado que son componentes básicos para demostrar el trabajo realizado, no se evaluará dicho trabajo o se colocará un puntaje en base a lo que pueda ser verificado.
- La cantidad de participantes por grupo será de 1 a 3 personas como máximo.
- Todos los miembros del grupo deben estar presentes durante la exposición, si un participante no viene a exponer no se le considerará la nota.