

# Análisis de los Indicadores de Ocupabilidad de MINCETUR

Hadoop MapReduce, clasificación y regresión

Sergio Sebastian Pezo Jimenez    Arbués Enrique Pérez Villegas

Universidad Nacional de Ingeniería  
CC531 Análisis en Macrodatos

22 de septiembre de 2026

- 1 Datos y antecedentes
- 2 Hadoop y consultas
- 3 Modelos y cierre
- 4 Referencias

- MINCETUR publica los indicadores en la Plataforma Nacional de Datos Abiertos.
- La encuesta registra capacidad y uso de hospedajes a nivel nacional y regional.
- El MEF usa estos indicadores como referencia para estimar demanda turística.

## Lo encontrado

Los estudios previos se concentran en una región y usan métodos estadísticos clásicos.

Fuentes: MINCETUR (2021), MEF (2021), Taípe y Laura (2021), Ñahuincopa y Rojas (2022).

---

|                     |             |
|---------------------|-------------|
| Periodo             | 2019–2025-I |
| Registros           | 38 730      |
| Columnas            | 24 columnas |
| Departamentos       | 25          |
| Archivos originales | 7           |

---

## Datos principales

- establecimientos, habitaciones y plazas-cama;
- TNOH, TNOC y permanencia;
- arribos, pernoctaciones y empleo.

Se conservaron intactos los CSV originales. El archivo canónico usa UTF-8, punto decimal y una cabecera común.

# Cómo la investigación guio las decisiones

| Hallazgo                           | Decisión tomada                                                            |
|------------------------------------|----------------------------------------------------------------------------|
| Estudios limitados a una región    | Comparar los 25 departamentos y varios periodos en Q01–Q10.                |
| cambio de esquema en 2024          | Normalizar nombres, orden y cantidad de columnas antes de cargar HDFS.     |
| Filas consolidadas mezcladas       | Aplicar TT/TT para evitar doble conteo en agregaciones nacionales.         |
| Predominio de regresiones clásicas | Comparar clasificación y regresión en Q11–Q14.                             |
| Datos mensuales ordenados          | Usar división temporal: entrenar con 2019–2023 y evaluar años posteriores. |

# Arquitectura Hadoop usada

- Hadoop 3.5.0 se ejecutó en un solo nodo levantado con Docker Compose.
- HDFS guardó la entrada y las salidas; YARN ejecutó y registró los JAR de MapReduce.

[Home](#)
[Overview](#)
[Databases](#)
[Database Volume Tables](#)
[Snapshots](#)
[Startup Progress](#)
[Utilities](#)

# Overview

## namenode:8020 (-active)

|                |                                                              |
|----------------|--------------------------------------------------------------|
| Started:       | Tue Sep 22 13:34:08 -0500 2010                               |
| Version:       | 3.5.6: d86c7d7910e6b330cd46f9b3ed1193a56af                   |
| Compiled:      | Tue Mar 24 13:58:00 -0500 2010 by crosstok from branch-3.5.0 |
| Cluster ID:    | CID-8706b0c-d6e7-4310-a80c-e0b0681180a6                      |
| Block Pool ID: | BP-1793538029-172.21.0.2-1780397642780                       |

## Summary

Security is off.

SafeMode is off.

470 files and directories, 208 blocks (208 replicated blocks, 0 resource coded block groups) = 878 total filesystem objects).

Heap Memory used 351.28 MB of 520 MB Heap Memory. Max Heap Memory is 9.05 GB.

Non Heap Memory used 88.2 MB of 65.63 MB Committed Non Heap Memory. Max Non Heap Memory is 'unbounded'.

|                             |           |
|-----------------------------|-----------|
| Configured Capacity:        | 422.28 GB |
| Configured Remote Capacity: | 0 B       |

### Entrada y bloques observados en NameNode.

[illegible]

### Aplicaciones finalizadas en ResourceManager.

# Consultas descriptivas: Q01–Q05

## Q01–Q05: ítem 1 de la práctica, cinco consultas con dos o más campos.

| Consulta | Pregunta                                 | Resultado destacado                                           |
|----------|------------------------------------------|---------------------------------------------------------------|
| Q01      | Arribos nacionales y extranjeros por año | En 2020 ambos grupos cayeron con fuerza.                      |
| Q02      | TNOH promedio por departamento y año     | Se observaron diferencias territoriales persistentes.         |
| Q03      | TNOH y TNOC por clase                    | Se comparó la ocupación de hoteles, resorts y otras clases.   |
| Q04      | Empleo por cada cien habitaciones        | Se relacionó personal reportado y capacidad por departamento. |
| Q05      | Arribos y pernoctaciones por mes         | Se revisó la estacionalidad de la demanda.                    |

**Ejemplo:** los arribos nacionales pasaron de 54,9 millones en 2019 a 34,6 millones en 2020.

# Estadística y consultas encadenadas: Q06–Q10

| Q06: ítem 2 |                                             | Q07: ítem 3 | Q08: ítem 4 | Q09–Q10: ítem 5                                  |
|-------------|---------------------------------------------|-------------|-------------|--------------------------------------------------|
| Consulta    | Tipo                                        |             |             | Resultado destacado                              |
| Q06         | Media, mediana y desviación de TNOH         |             |             | Media 21,74; mediana 21,34.                      |
| Q07         | Búsqueda de subtexto                        |             |             | Filtrado configurable por departamento.          |
| Q08         | Máximo y mínimo anual                       |             |             | Identificó extremos departamentales.             |
| Q09         | Dos jobs: cambio 2019–2024                  |             |             | Apurímac: –18,73 pp; Ucayali: +5,04 pp.          |
| Q10         | Dos jobs: participación extranjera en Cusco |             |             | 63,37 % antes de 2020 y 58,35 % en recuperación. |



Q11–Q12: ítem 6 de la práctica, dos modelos de clasificación.

| Modelo          | F1 2024       | F1 2025-I     |
|-----------------|---------------|---------------|
| Q11 Naive Bayes | 0,4403        | 0,4675        |
| Q12 Logística   | <b>0,7931</b> | <b>0,6939</b> |

## Lectura

La regresión logística logró un mejor equilibrio entre precisión y recall en ambos periodos.

La etiqueta separó ocupabilidad alta y baja usando la mediana de TNOH del entrenamiento.

Q13–Q14: ítem 7 de la práctica, dos modelos de regresión.

| Modelo     | 2024          |               | 2025-I        |               |
|------------|---------------|---------------|---------------|---------------|
|            | RMSE          | $R^2$         | RMSE          | $R^2$         |
| Q13 Lineal | 4,0920        | 0,6435        | 3,9273        | 0,6622        |
| Q14 Ridge  | <b>4,0726</b> | <b>0,6469</b> | <b>3,8796</b> | <b>0,6703</b> |

Ridge redujo un poco el

error, pero la mejora fue pequeña. Los dos modelos conservaron la misma división temporal y las mismas variables.

- Se logró unificar siete CSV sin modificar los originales.
- Las catorce consultas dejaron salida real y un JAR reproducible.
- La investigación previa ayudó a normalizar el esquema, evitar doble conteo y elegir una evaluación temporal.
- La regresión logística obtuvo el mejor F1 y ridge mejoró ligeramente el RMSE.

## Límites

2025 contiene solo seis meses. El clúster tuvo un nodo y el dataset no representa macrodatos por volumen.

# Referencias I



Ministerio de Comercio Exterior y Turismo, “Indicadores de Ocupabilidad,” Plataforma Nacional de Datos Abiertos, 2021. [En línea]. Disponible en: <https://www.datosabiertos.gob.pe/dataset/indicadores-de-ocupabilidad-ministerio-de-comercio-exterior-y-turismo->



Ministerio de Economía y Finanzas, “Ficha Técnica Simplificada para proyectos de inversión pública en servicios turísticos,” Lima, Perú, 2021.



H. Taipe Pari y J. G. Laura Huamán, “Desestacionalización de la serie de tiempo llegada mensual de turistas y la oferta de hospedaje en la región Huancavelica, periodo 2003–2019,” Universidad Nacional de Huancavelica, 2021.



J. Dean y S. Ghemawat, “MapReduce: Simplified Data Processing on Large Clusters,” *Communications of the ACM*, vol. 51, no. 1, pp. 107–113, 2008, doi: 10.1145/1327452.1327492.



A. P. Viteri Gonzales y J. A. Beltrán García, “Solución de big data para el análisis de datos abiertos de MINSA y CENARES bajo Apache Hadoop y Microsoft Azure,” Universidad Privada Antenor Orrego, 2023.



M. Mariani y R. Baggio, "Big data and analytics in hospitality and tourism: A systematic literature review," *International Journal of Contemporary Hospitality Management*, vol. 34, no. 1, pp. 231–278, 2022, doi: 10.1108/ijchm-03-2021-0301.