Indicadores de Ocupabilidad de MINCETUR

14 flujos MapReduce con output

Sergio Sebastian Pezo Jimenez Arbués Enrique Pérez Villegas

Universidad Nacional de Ingeniería
CC531 Análisis en Macrodatos

22 de septiembre de 2026

Contenido

1. Datos y entorno
2. Tipos de consulta: resumen
3. Consultas con dos o más columnas: ítem 1
4. Medidas estadísticas: ítem 2
5. Búsqueda de subtexto: ítem 3
6. Máximo y mínimo agrupados: ítem 4
7. Dos MapReduce enlazados: ítem 5
8. Feature Vector — ítem 6: clasificación

Dataset

Qué representa una fila

Un mes, un departamento y un nivel clase–categoría; no representa un hotel individual.

- 2019–2025-I, 38 730 filas y 24 columnas.
- 25 departamentos; 2025 contiene seis meses.
- `TT` existe en `ID_CLASE` y `ID_CATEGORIA`.
- `TT/TT` es nuestra abreviatura para ese par de valores; no es otra columna.

Indicadores que originan las preguntas

- **TNOH**: porcentaje de habitaciones disponibles ocupadas.
- **TNOC**: porcentaje de plazas-cama disponibles ocupadas.
- **Arribo**: huésped contado al llegar.
- **Pernoctación**: cada noche que permanece.

Regla de análisis

Filtramos TT/TT cuando buscamos totales departamentales: sumar esos totales junto con sus desagregaciones contaría la misma actividad varias veces.

Columnas

Columna	Significado
FECHA_CORTE	Actualización de la fuente.
ANIO	Año observado.
MES	Mes, de 01 a 12.
ID_CLASE	Código de clase; TT es total.
CLASE	Hotel, hostal, resort, etc.
ID_CATEGORIA	Código de categoría; TT es total.
CATEGORIA	Estrellas o no categorizado.
DEPARTAMENTO	Región de agregación.
ID_UBIGEO	Código geográfico del INEI.
NUMERO_ESTABLECIMIENTOS	Hospedajes incluidos.
NUMERO_HABITACIONES	Habitaciones ofertadas.
NUMERO_PLAZAS_CAMA	Camas disponibles; doble cuenta como dos.

Columna	Significado
PORCENTAJE_TNOH	Ocupación de habitaciones.
PORCENTAJE_TNOC	Ocupación de plazas-cama.
PROMEDIO_PERMANENCIA	Días promedio por huésped.
PROMEDIO_PERMANENCIA_NAC	Permanencia de nacionales.
PROMEDIO_PERMANENCIA_EXT	Permanencia de extranjeros.
TOTAL_ARRIBOS	Huéspedes registrados al llegar.
TOTAL_ARRIBOS_NAC	Arribos nacionales.
TOTAL_ARRIBOS_EXT	Arribos extranjeros.
TOTAL_PERNOCT	Noches ocupadas totales.
TOTAL_PERNOCT_NAC	Noches de nacionales.
TOTAL_PERNOCT_EXT	Noches de extranjeros.
TOTAL_EMPLEO	Personas empleadas en el mes.

TNOH y TNOC son porcentajes; arribos y pernoctaciones son cantidades.

Tipos y preguntas de las 14 consultas

Q	Ítem	Grupo de la práctica	Pregunta
01	1a	Dos o más columnas	¿Cómo evolucionaron los arribos nacionales y extranjeros por año?
02	1b	Dos o más columnas	¿Cuál fue la TNOH media de cada departamento por año?
03	1c	Dos o más columnas	¿Cómo cambian la TNOH y la TNOC según la clase de hospedaje?
04	1d	Dos o más columnas	¿Cuántos empleos existen por cada cien habitaciones en cada departamento y año?
05	1e	Dos o más columnas	¿Qué meses concentran más arribos y pernoctaciones?
06	2	Medidas estadísticas	¿Cuál es la cantidad, media, mediana y desviación de la TNOH?
07	3	Búsqueda de subtexto	¿Qué registros contienen un texto en clase, categoría o departamento?
08	4	Máximo y mínimo agrupados	¿Qué departamentos tuvieron la menor y mayor TNOH media de cada año?
09	5a	Dos MapReduce enlazados	¿Cuánto cambió la TNOH entre 2019 y 2024?
10	5b	Dos MapReduce enlazados	¿Qué porcentaje de arribos fue extranjero en cada periodo?
11	6a	Modelo de clasificación	¿La TNOH es alta o baja según los otros indicadores?
12	6b	Modelo de clasificación	¿La TNOH mensual departamental es alta o baja según los demás indicadores?
13	7a	Modelo de regresión	¿Qué valor continuo de TNOH estiman los indicadores?
14	7b	Modelo de regresión	¿Qué TNOH se estima al controlar los coeficientes con regularización L2?

Q01 — Ítem 1a: arribos por origen

Pregunta

¿Cómo evolucionaron los arribos nacionales y extranjeros por año?

Input, filas y código. CSV canónico; `ANIO`, `TOTAL_ARRIBOS_NAC` y `TOTAL_ARRIBOS_EXT`; filas TT/TT. Clases `ArrivalsMapper/Reducer`.

Mapper. Filtra TT/TT y emite `(ANIO) -> (ARRIBOS_NAC, ARRIBOS_EXT)`.

Reducer. Agrupa por año, suma ambos orígenes y emite `(ANIO) -> (national=SUMA, foreign=SUMA)`.

Output real.

```
2019 national=54897127 foreign=8264767
2020 national=34588588 foreign=1778619
2024 national=50875669 foreign=6690972
2025 national=26355966 foreign=3610473
```

Respuesta e interpretación. La serie evidencia la caída de 2020 y la recuperación posterior. 2025-I no se compara como un año completo.

Q02 — Ítem 1b: TNOH territorial

Pregunta

¿Cuál fue la TNOH media de cada departamento por año?

Input, filas y código. CSV canónico; `ANIO`, `DEPARTAMENTO`, `PORCENTAJE_TNOH`; filas TT/TT. Clases `OccupancyMapper/Reducer`.

Mapper. Emite `(ANIO;DEPARTAMENTO) -> (TNOH, 1)` para cada fila TT/TT.

Reducer. Agrupa meses, divide suma entre cantidad y emite `(ANIO;DEPARTAMENTO) -> (mean_tnoh)`.

Output real.

```
2019;CALLAO mean_tnoh=40.9142
2020;CALLAO mean_tnoh=25.7092
2024;CALLAO mean_tnoh=41.5950
2024;LORETO mean_tnoh=12.9917
```

Respuesta e interpretación. En 2024 Callao tuvo una TNOH media muy superior a Loreto. Es una media mensual no ponderada por habitaciones.

Q03 — Ítem 1c: ocupación por clase

Pregunta

¿Cómo cambian la TNOH y la TNOC según la clase de hospedaje?

Input, filas y código. CSV canónico; `ANIO`, `CLASE`, `PORCENTAJE_TNOH/TNOC`; categoría TT y clase distinta de TT. `OccupancyMapper/Reducer`.

Mapper. Conserva categoría TT, excluye clase TT y emite `(ANIO;CLASE) -> (TNOH, TNOC, 1)`.

Reducer. Agrupa por año-clase y emite `(ANIO;CLASE) -> (mean_tnoh, mean_tnoc)`.

Output real.

```
2019;HOTEL mean_tnoh=31.2412 mean_tnoc=26.3323
2020;HOTEL mean_tnoh=21.1950 mean_tnoc=16.1440
2024;HOTEL mean_tnoh=32.4184 mean_tnoc=27.6639
2024;RESORT mean_tnoh=46.7742 mean_tnoc=48.2812
```

Respuesta e interpretación. Los resorts muestran ocupación alta de habitaciones y camas. Ambas tasas difieren porque una habitación puede alojar varias personas.

Q04 — Ítem 1d: empleo por capacidad

Pregunta

¿Cuántos empleos existen por cada cien habitaciones en cada departamento y año?

Input, filas y código. CSV canónico; `ANIO`, `DEPARTAMENTO`, `TOTAL_EMPLEO`, `NUMERO_HABITACIONES`; TT/TT. `CapacityMapper/Reducer`.

Mapper. Filtra TT/TT y emite `(ANIO;DEPARTAMENTO) -> (EMPLEO, HABITACIONES)`.

Reducer. Suma ambos campos y emite `(ANIO;DEPARTAMENTO) -> (100*EMPLEO/HABITACIONES)`.

Output real.

```
2019;LIMA employment_per_100_rooms=74.3232
2024;LIMA employment_per_100_rooms=54.3562
2024;CALLAO employment_per_100_rooms=28.4118
2024;TACNA employment_per_100_rooms=15.0163
```

Respuesta e interpretación. Lima registró 54.36 empleos por cien habitaciones en 2024. La razón no mide productividad ni calidad laboral.

Q05 — Ítem 1e: estacionalidad

Pregunta

¿Qué meses concentran más arribos y pernoctaciones?

Input, filas y código. CSV canónico; `MES`, `TOTAL_ARRIBOS`, `TOTAL_PERNOCT`; filas TT/TT. `SeasonalityMapper/Reducer`.

Mapper. Emite `(MES) -> (ARRIBOS, PERNOCTACIONES)` para cada total TT/TT.

Reducer. Agrupa el mismo mes y emite `(MES) -> (SUMA_ARRIBOS, SUMA_PERNOCT)`.

Output real.

```
01 arrivals=33585654 overnight_stays=43787718
02 arrivals=32795352 overnight_stays=42942772
07 arrivals=26760124 overnight_stays=35417748
09 arrivals=26098980 overnight_stays=33472076
```

Respuesta e interpretación. Enero concentra el mayor volumen acumulado; enero–junio incluye 2025-I y tiene un periodo adicional.

Q06 — Ítem 2: medidas estadísticas

Pregunta

¿Cuál es la cantidad, media, mediana y desviación estándar poblacional de la TNOH?

Input, filas y código. CSV canónico; `PORCENTAJE_TNOH`; 1 950 filas TT/TT. `StatisticsMapper/Reducer`.

Mapper. Emite cada tasa bajo una clave constante: `(TNOH) -> (VALOR)`.

Reducer. Agrupa 1 950 valores y emite `(TNOH) -> (count, mean, median, stddev)`.

Output real. `count=1950 mean=21.7433 median=21.3400 stddev=7.0679`

Respuesta e interpretación. La ocupación mensual típica ronda 21 puntos y su desviación es 7.07. Centralizar los valores solo es viable por el tamaño pequeño.

Q07 — Ítem 3: búsqueda de subtexto

Pregunta

¿Qué registros contienen un texto en clase, categoría o departamento?

Input, filas y código. CSV canónico completo; `CLASE`, `CATEGORIA`, `DEPARTAMENTO`; término configurable. `SearchMapper`, sin Reducer.

Mapper. Si existe coincidencia, emite `(OFFSET) -> (FILA_COMPLETA)`.

Reducer. No hay Reducer; la salida final conserva `(OFFSET) -> (FILA_COMPLETA)`.

Output real.

```
matches=11525
2424268 ;2022;06;HOTEL;1 ESTRELLA;AMAZONAS;...
2424367 ;2022;06;HOTEL;1 ESTRELLA;PIURA;...
```

Respuesta e interpretación. La búsqueda literal encontró 11 525 filas con “hotel”. No reconoce sinónimos ni normaliza acentos.

Q08 — Ítem 4: máximo y mínimo

Pregunta

¿Qué departamentos tuvieron la menor y mayor TNOH media de cada año?

Input, filas y código. CSV canónico; `ANIO`, `DEPARTAMENTO`, `PORCENTAJE_TNOH`; TT/TT. `ExtremesMapper/Reducer`.

Mapper. Emite `(ANIO) -> (DEPARTAMENTO, TNOH)` para las filas TT/TT.

Reducer. Calcula medias y emite `(ANIO) -> (min=DEP:MEDIA, max=DEP:MEDIA)`.

Output real.

```
2019 min=TACNA:20.7342 max=CALLAO:40.9142
2020 min=TACNA:9.6425 max=CALLAO:25.7092
2024 min=LORETO:12.9917 max=CALLAO:41.5950
2025 min=AYACUCHO:14.1217 max=CALLAO:43.9917
```

Respuesta e interpretación. Loreto y Callao delimitan los extremos de 2024. Los dos cálculos ocurren dentro de un solo Reducer.

Q09 — Ítem 5a: dos MapReduce enlazados

Pregunta

¿Cuántos puntos porcentuales cambió la TNOH media entre 2019 y 2024?

Input, filas y código. CSV canónico; año, departamento y TNOH; solo TT/TT de 2019 y 2024. `AnnualMapper/Reducer` y `ChangeMapper/Reducer`.

Job 1: agregación

Mapper. Emite `(ANIO;DEP) -> (TNOH, 1)`.

Reducer. Agrupa meses. Salida job 1: `(ANIO;DEP) -> (MEDIA_TNOH)`.

Job 2: comparación

Mapper. Lee esa salida y emite `(DEP) -> (ANIO, MEDIA_TNOH)`.

Reducer. Une ambos años. Salida job 2: `(DEP) -> (2019, 2024, change_pp)`.

Output real.

```
LA LIBERTAD 2019=30.7350 2024=14.7108 change_pp=-16.0242
CALLAO 2019=40.9142 2024=41.5950 change_pp=0.6808
CUSCO 2019=26.9108 2024=28.2725 change_pp=1.3617
UCAYALI 2019=25.1383 2024=30.1825 change_pp=5.0442
```

Respuesta e interpretación. Apurímac tuvo la mayor caída y Ucayali el mayor aumento; el cambio no demuestra causalidad.

Q10 — Ítem 5b: dos MapReduce enlazados

Pregunta

¿Qué porcentaje de los arribos fue extranjero en cada departamento y periodo?

Input, filas y código. CSV canónico; año, mes, departamento, arribos totales y extranjeros; TT/TT con arribos > 0. `MonthlyMapper/Reducer` y `PeriodMapper/Reducer`.

Job 1: agregación

Mapper. Emite `(DEP;PERIODO;ANIO;MES) -> (CUOTA_EXT, 1)`.

Reducer. Consolida el mes. Salida job 1: `(DEP;PERIODO) -> (CUOTA_MENSUAL)`.

Job 2: comparación

Mapper. Lee esa salida y emite `(DEP;PERIODO) -> (CUOTA_MENSUAL, 1)`.

Reducer. Promedia meses. Salida job 2: `(DEP;PERIODO) -> (mean_foreign_share)`.

Output real.

```
CUSCO;PRE_2019 mean_foreign_share=63.3747
CUSCO;IMPACT_2020_2021 mean_foreign_share=20.5234
CUSCO;RECOVERY_2022_2024 mean_foreign_share=58.3507
CUSCO;CURRENT_2025_H1 mean_foreign_share=67.4504
```

Respuesta e interpretación. Cusco cayó durante 2020–2021 y luego se recuperó. Es una media mensual no ponderada por arribos.

Feature Vector — Ítem 6: clasificación

Las 7 características predictoras

1. `MES`.
2. `NUMERO_ESTABLECIMIENTOS`.
3. `NUMERO_HABITACIONES`.
4. `NUMERO_PLAZAS_CAMA`.
5. `TOTAL_ARRIBOS / NUMERO_HABITACIONES`.
6. `TOTAL_PERNOCT / NUMERO_PLAZAS_CAMA`.
7. `TOTAL_EMPLEO / NUMERO_ESTABLECIMIENTOS`.

Objetivo y variables auxiliares

- El CSV aporta la **TNOH numérica**, no una columna ALTA/BAJA.
- Etiqueta creada: TNOH $\geq 21{,}71\,\%$ = ALTA; en otro caso = BAJA.
- `ANIO` solo divide entrenamiento (2019–2023), prueba (2024) y validación (2025-I).
- `DEPARTAMENTO`, clase y categoría no son predictores; clase/categoría solo filtran `TT/TT`.
- Q11 usa los valores numéricos; Q12 los estandariza con estadísticas del entrenamiento.

```
(MODEL) -> (ANIO | TNOH | MES, ESTAB., HAB., CAMAS, ARR/HAB., PERN/CAMA,
                                                        EMP/ESTAB.)
```

Q11 — Ítem 6a: clasificación Naive Bayes

Pregunta

¿La TNOH mensual departamental es alta o baja según los demás indicadores?

Input, filas y código. 1 950 filas TT/TT; TNOH objetivo y 7 características de capacidad/actividad; entrenamiento 2019–2023. `ModelMapper/Reducer`.

Mapper. Emite `(MODEL) -> (ANIO | TNOH | X1,...,X7)` para cada fila TT/TT.

Reducer. Agrupa ejemplos, entrena y emite `(PERIODO) -> (samples, matriz, accuracy, F1, log_loss)`.

Output real.

```
TRAINING samples=1500 threshold=21.7100
TEST_2024 samples=300 accuracy=0.703333 recall=0.286885 f1=0.440252
VALIDATION_2025_H1 samples=150 accuracy=0.726667 recall=0.305085 f1=0.467532
```

Respuesta e interpretación. El recall bajo indica que el modelo omite muchos casos de ocupación alta; funciona como línea base probabilística.

Q12 — Ítem 6b: clasificación logística

Pregunta

¿La TNOH mensual departamental es alta o baja según los demás indicadores?

Input, filas y código. Mismo input y partición de Q11; 7 características estandarizadas con entrenamiento. `ModelMapper/Reducer`.

Mapper. Emite `(MODEL) -> (ANIO | TNOH | X1,...,X7)`, igual que Q11.

Reducer. Estandariza, entrena y emite `(PERIODO) -> (samples, matriz, accuracy, F1, log_loss)`.

Output real.

```
TRAINING samples=1500 iterations=200 learning_rate=0.1000
TEST_2024 samples=300 accuracy=0.840000 recall=0.754098 f1=0.793103
VALIDATION_2025_H1 samples=150 accuracy=0.800000 recall=0.576271 f1=0.693878
```

Respuesta e interpretación. La regresión logística mejoró claramente recall y F1 frente a Naive Bayes con los mismos datos.

Ítem 6 — Comparación de clasificación

Periodo	Modelo	Accuracy	Prec.	Recall	F1	Log loss
2024	Naive Bayes	0.7033	0.9459	0.2869	0.4403	0.9470
2024	Logística	0.8400	0.8364	0.7541	0.7931	0.4988
2025-I	Naive Bayes	0.7267	1.0000	0.3051	0.4675	0.8545
2025-I	Logística	0.8000	0.8718	0.5763	0.6939	0.4748

Lectura principal

Naive Bayes fue muy preciso cuando predijo ocupación alta, pero detectó pocos casos altos. La logística obtuvo mejor equilibrio, mayor F1 y menor log loss en ambos periodos.

Feature Vector — Ítem 7: regresión

Las 7 características de Q13 y Q14

1. `MES`.
2. `NUMERO_ESTABLECIMIENTOS`.
3. `NUMERO_HABITACIONES`.
4. `NUMERO_PLAZAS_CAMA`.
5. `TOTAL_ARRIBOS / NUMERO_HABITACIONES`.
6. `TOTAL_PERNOCT / NUMERO_PLAZAS_CAMA`.
7. `TOTAL_EMPLEO / NUMERO_ESTABLECIMIENTOS`.

Tratamiento antes de entrenar

- Objetivo continuo: `PORCENTAJE_TNOH`; aquí no se convierte en ALTA/BAJA.
- Las siete entradas se estandarizan: $z = (x - \mu)/\sigma$, con μ y σ de 2019–2023.
- No se codifican variables categóricas: departamento, clase y categoría quedan fuera del vector.
- `MES` se trata como número 1–12, no con one-hot ni codificación cíclica; es una limitación.
- Q13 usa $\lambda = 0$; Q14 conserva el mismo vector y usa Ridge con $\lambda = 1$.

`(MODEL) -> (ANIO | TNOH | X1,...,X7)`

Q13 — Ítem 7a: regresión lineal

Pregunta

¿Qué valor continuo de TNOH puede estimarse usando los demás indicadores?

Input, filas y código. 1 950 filas TT/TT; TNOH continua y las mismas 7 características; entrenamiento 2019–2023. `ModelMapper/Reducer`.

Mapper. Emite `(MODEL) -> (ANIO | TNOH | X1,...,X7)` para cada fila TT/TT.

Reducer. Ajusta $\lambda = 0$ y emite `(PERIODO) -> (samples, MAE, RMSE, R2)`.

Output real.

```
TRAINING samples=1500 lambda=0
TEST_2024 samples=300 mae=3.192221 rmse=4.092002 r_squared=0.643537
VALIDATION_2025_H1 samples=150 mae=3.020832 rmse=3.927314 r_squared=0.662158
```

Respuesta e interpretación. El MAE fue 3.19 puntos y el modelo explicó 64.35 % de la variación de 2024.

Q14 — Ítem 7b: regresión Ridge

Pregunta

¿Qué TNOH se estima al controlar el tamaño de los coeficientes con regularización L2?

Input, filas y código. Mismo input, características y periodos de Q13; Ridge con $\lambda = 1$. `ModelMapper/Reducer`.

Mapper. Emite `(MODEL) -> (ANIO | TNOH | X1,...,X7)`, igual que Q13.

Reducer. Ajusta $\lambda = 1$ y emite `(PERIODO) -> (samples, MAE, RMSE, R2)`.

Output real.

```
TRAINING samples=1500 lambda=1
TEST_2024 samples=300 mae=3.194316 rmse=4.072566 r_squared=0.646915
VALIDATION_2025_H1 samples=150 mae=3.013257 rmse=3.879584 r_squared=0.670320
```

Respuesta e interpretación. Ridge mejoró ligeramente RMSE y R^2; solo se evaluó un valor de λ.

Ítem 7 — Comparación de regresión

Periodo	Modelo	MAE	RMSE	R^2
2024	Lineal	3.1922	4.0920	0.6435
2024	Ridge	3.1943	4.0726	0.6469
2025-I	Lineal	3.0208	3.9273	0.6622
2025-I	Ridge	3.0133	3.8796	0.6703

Lectura principal

Ridge redujo ligeramente los errores grandes medidos por RMSE y aumentó R^2. La diferencia es pequeña: no basta para declarar una superioridad fuerte ni un λ óptimo.

Conclusiones: de preguntas a respuestas

Qué respondimos

- Q01–Q05: evolución, territorio, clase, capacidad y estacionalidad.
- Q06–Q08: distribución, búsqueda y extremos.
- Q09–Q10: cambio temporal y participación extranjera con dos jobs.
- Q11–Q12: la logística logró mejor equilibrio; F1=0.7931 en 2024.
- Q13–Q14: Ridge mejoró ligeramente; RMSE=3.8796 en 2025-I.

Hasta dónde llegan las respuestas

No prueban causalidad. 2025 tiene seis meses. Algunos promedios no ponderan capacidad. Un nodo valida el pipeline, no escalabilidad. Los modelos caben en un reducer por el volumen pequeño.

Referencias I

- Ministerio de Comercio Exterior y Turismo, "Indicadores de Ocupabilidad," Plataforma Nacional de Datos Abiertos, 2021.
- Ministerio de Economía y Finanzas, "Ficha Técnica Simplificada para proyectos turísticos," 2021.
- J. Dean y S. Ghemawat, "MapReduce: Simplified Data Processing on Large Clusters," *Communications of the ACM*, vol. 51, no. 1, pp. 107–113, 2008.
- M. Mariani y R. Baggio, "Big data and analytics in hospitality and tourism: A systematic literature review," *International Journal of Contemporary Hospitality Management*, vol. 34, no. 1, pp. 231–278, 2022.

Preguntas y demostración