# Instalación y Configuración de Hadoop en un Cluster de 3 nodos

## Paso 1: Requerimientos y Preparación de la VM

1. **Software Necesario:**
    - **VirtualBox:** Instálalo en tu PC real (Anfitrión).
    - **ISO de Linux:** Se recomienda **Ubuntu Server** o **Linux Mint** (por ser ligeros).
2. **Crear la VM "Base":**
    - Crea una nueva VM llamada `Hadoop-Master`.
    - Desmarcar la casilla **Proceder con instalación desatendida**
    - Asigna **2GB de RAM** y **25GB de disco**.
    - En **Configuración** de la VM recién creada, ve a la sección **Red** -> *Adaptador2* -> *Habilitar adaptador de Red*.
    - Selecciona **Adaptador Solo Anfitrión** y luego **Aceptar**.
3. **Instalación de Ubuntu Server:**
    - Procede con la instalación normal.
    - Al momento de configurar el usuario, indica:
        - **Nombre de equipo:** `master`
        - **Usuario:** `hadoop`
    - Marca la casilla **Instalar OpenSSH Server**.
    - Espera que termine la instalación.

---

## Paso 2: Configuración del Sistema

Una vez instalada la VM Base, vamos a instalar las herramientas necesarias y configurar la red para que los nodos puedna comunicarse entre sí.

1. **Instalar y activar OpenSSH Server** (Si no lo instalaste junto al Ubuntu)

```
# Instalación de OpenSSH Server
sudo apt update
sudo apt install openssh-server -y

# Activa el servicio
sudo systemctl enable --now ssh

# Verifica que se activo correctamente. Debería ver un mensaje en verde que
diga active (running)
sudo systemctl status ssh
```

2. **Instalar Java 11**

```
sudo apt update
sudo apt install openjdk-11-jdk openssh-server -y
```

3. **Configuración de IPs estáticas**:

   Vamos a fijar las direcciones IP del clúster para evitar problemas al clonar las VM o si se reinician. Primero hay que comprobar la interfaz de red que se va a modificar.

```
ip a
```

   Aqui deberían aparecer 3 interfaces de red. La red NAT suele tener el nombre `enp0s3` y su IP la forma `10.0.X.X`, y la red Solo-Anfitrión suele tener el nombre `enp0s8` y, o no tiene dirección IP o tiene una de la forma `192.168.X.X`. A continuación vamos a fijar las direcciones IP:

```
sudo nano /etc/netplan/00-installer-config.yaml
```

   Modifica el archivo de esta forma:

```
network:
  ethernets:
    enp0s3:
      dhcp4: true
      dhcp6: true
    enp0s8:
      accept-ra: no
      dhcp4: no
      dhco6: no
      addresses:
       - 192.168.56.10/24
  version: 2
```

   Finalmente, aplica los cambios:

```
sudo netplan apply
```

4. **Modificar hostnames para el cluster**.

```
sudo nano /etc/hosts
```

En el editor de texto, agregar al final:

```
192.168.56.10 master
192.168.56.11 worker1
192.168.56.12 worker2
```

Para evitar problemas más adelante, comentar la línea que contiene el nombre `master` al principio del archivo. Debería verse algo así:

```
127.0.0.1 localhost
# 127.0.1.1 master
```

5. **Reiniciar para ver los cambios**

```
sudo reboot
```

Después de reiniciar la VM, se debería ver la interfaz de red con la IP estática:

```
ip a
```

## Paso 3: Clonar las VM

1. **En VirtualBox**
    - Haz clic derecho en la VM y selecciona **Clonar**.
    - En el menú:
        - **Nombre**: Hadoop-Worker1
        - **Tipo de clon**: Clonación completa
        - **Política de Dirección MAC**: Generar nuevas direcciones MAC para todos los adaptadores de red.
    - Haz clic en **Terminar** y arranca la VM recién clonada.
2. **Modifica el hostname**

```
sudo hostnamectl set-hostname worker1
```

3. **Modifica la IP estática**

```
sudo nano /etc/netplan/00-installer-config.yaml
```

En el editor de texto, modifica la dirección IP de la interfaz `enp0s8` a su IP correspondiente:

```
network:
  ethernets:
    enp0s3:
      dhcp4: true
      dhcp6: true
    enp0s8:
      accept-ra: no
      dhcp4: no
      dhcp6: no
      addresses:
       - 192.168.56.11/24 <---- AQUI CAMBIA LA IP
  version: 2
```

Luego aplicar los cambios:

```
sudo netplan apply
```

4. **Reinicia la VM y comprobar cambios**

```
sudo reboot
```

Después de reiniciar, se debería notar el cambio de hostname. Ahora deberia aparecer `hadoop@worker1` en línea de comandos. Luego, ejecutando `ip a` se debería ver el cambio en dirección IP.

Para verificar la conexión, desde el **master** manda un ping al **worker** recien configurado:

```
ping -c 3 worker1
```

5. **Repite...**.

Repite estos pasos por cada nodo **worker** que desees. Solo procura que cada uno tenga una IP estática única y que figure correctamente en `/etc/hosts`.

# Paso 4: Configurar SSH (EN EL NODO MASTER)

1. **Crear archivo de configuración**

```
mkdir -p ~/.ssh
chmod 700 ~/.ssh
nano ~/.ssh/config
```

En el editor de texto, escribe:

```
Host master
    HostName 192.168.56.10
    User hadoop
    StrictHostKeyChecking accept-new

Host worker1
    HostName 192.168.56.11
    User hadoop
    StrictHostKeyChecking accept-new

Host worker2
    HostName 192.168.56.12
    User hadoop
    StrictHostKeyChecking accept-new
```

Finalmente, define los permisos del nuevo archivo config:

```
chmod 600 ~/.ssh/config
```

2. **Crea y distribuye llaves SSH**

```
# Genera llaves sin passkey
ssh-keygen -t rsa -P ""

# Distribuye las llaves a los nodos
ssh-copy-id master
ssh-copy-id worker1
ssh-copy-id worker2
```

3. **Verifica la conexión**

```
ssh worker1 'hostname && whoami'
```

"

## Paso 5: Instalación de Hadoop (En el nodo MASTER)

1. **Descarga Hadoop 3.3.6**

```
wget https://archive.apache.org/dist/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz
```

2. **Descomprime el archivo descargado**

```
tar -xvzf hadoop-3.3.6.tar.gz
```

3. **Renombra carpeta descomprimida y elimina el comprimido**

```
mv hadoop-3.3.6 hadoop
rm hadoop-3.3.6.tar.gz
```

## Paso 6: Configuración de Hadoop (En MASTER)

1. **Variables de entorno**

```
sudo nano ~/.bashrc
```

En el editor de texto, agregar al final:

```
export HADOOP_HOME=$HOME/hadoop
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/bin
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
```

Finalmente para cargar los cambios:

```
source ~/.bashrc
```

2. **Configurar hadoop-env.sh**

```
nano ~/hadoop/etc/hadoop/hadoop-env.sh
```

En el editor de texto, agregar:

```
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
```

3. **Configurar core-site.xml**

```
nano ~/hadoop/etc/hadoop/core-site.xml
```

En el editor de texto, agregar:

```
<configuration>
    <property>
        <name>fs.defaultFS</name>
        <value>hdfs://master:9000</value>
    </property>
</configuration>
```

4. **Configurar hdfs-site.xml**

```
nano ~/hadoop/etc/hadoop/hdfs-site.xml
```

En el editor de texto, agregar:

```
<configuration>
    <property>
        <name>dfs.replication</name>
        <value>2</value>
    </property>
    <property>
        <name>dfs.namenode.name.dir</name>
```

```
        <value>file:///home/hadoop/hadoop_data/hdfs/namenode</value>
    </property>
    <property>
        <name>dfs.datanode.data.dir</name>
        <value>file:///home/hadoop/hadoop_data/hdfs/datanode</value>
    </property>
</configuration>
```

5. **Configurar mapred-site.xml**

```
nano ~/hadoop/etc/hadoop/mapred-site.xml
```

En el editor de texto, agregar:

```
<configuration>
    <property>
        <name>mapreduce.framework.name</name>
        <value>yarn</value>
    </property>
    <property>
        <name>mapreduce.application.classpath</name>

<value>$HADOOP_HOME/share/hadoop/mapreduce/*:$HADOOP_HOME/share/hadoop/mapred
uce/lib/*</value>
    </property>
    <property>
        <name>yarn.app.mapreduce.am.env</name>
        <value>HADOOP_MAPRED_HOME=${HADOOP_HOME}</value>
    </property>
    <property>
        <name>mapreduce.map.env</name>
        <value>HADOOP_MAPRED_HOME=${HADOOP_HOME}</value>
    </property>
    <property>
        <name>mapreduce.reduce.env</name>
        <value>HADOOP_MAPRED_HOME=${HADOOP_HOME}</value>
    </property>

</configuration>
```

6. **Configurar yarn-site.xml**

```
nano ~/hadoop/etc/hadoop/yarn-site.xml
```

En el editor de texto, agregar:

```
<configuration>
    <property>
        <name>yarn.nodemanager.aux-services</name>
        <value>mapreduce_shuffle</value>
    </property>
    <property>
        <name>yarn.resourcemanager.hostname</name>
        <value>master</value>
    </property>
</configuration>
```

7. **Configurar workers**

```
nano ~/hadoop/etc/hadoop/workers
```

En el editor de texto, agregar:

```
worker1
worker2
```

## Paso 7: Instalar Hadoop en Workers y sincronizar los cambios

1. **Crear carpetas para Namenode y Datanode en cada nodo**

```
mkdir -p ~/hadoop_data/hdfs/namenode
mkdir -p ~/hadoop_data/hdfs/datanode
```

También puedes crear las carpetas en los workers desde el master via SSH

```
ssh worker1 'mkdir -p ~/hadoop_data/hdfs/datanode'
ssh worker1 'mkdir -p ~/hadoop_data/hdfs/namenode'

ssh worker2 'mkdir -p ~/hadoop_data/hdfs/datanode'
ssh worker2 'mkdir -p ~/hadoop_data/hdfs/namenode'
```

2. **Enviar la carpeta hadoop a los workers**

```
scp -r ~/hadoop worker1:~/
scp -r ~/hadoop worker2:~/
```

3. **Enviar .bashrc a los workers**

```
scp ~/.bashrc worker1:~/
scp ~/.bashrc worker2:~/
```

Debes cargar los cambios en el mismo nodo usando `source ~/.bashrc`

## Paso 8: Iniciar Hadoop (en Master)

1. **Formatea el Namenode**

```
hdfs namenode -format
```

2. **Inicia los servicios de archivos distribuidos (HDFS) y el gestor de recursos (YARN)**

```
start-dfs.sh
start-yarn.sh
```

3. **Verificar**

```
jps
```

Deberia aparecer `NameNode`, `SecondaryNameNode` y `ResourceManager` en el **master**; y `DataNode` y `NodeManager` en los **workers**.

## Paso 9: Ejecución de ejemplo

1. **Generar un archivo de prueba**

```
# Crear un archivo de prueba de 10 000 líneas de texto...
yes "Este es un archivo de prueba para el curso de Análisis de Macrodatos" |
head -n 10000 > datos_prueba.txt
```

2. **Cargar el archivo al HDFS**

```
# Crear la carpeta de entrada en HDFS
hdfs dfs -mkdir -p /input

# Subir el archivo generado
hdfs dfs -put datos_prueba.txt /input/
```

```
# Verificar que el archivo ya vive en el clúster
hdfs dfs -ls /input/
```

3. **Ejecutamos un WordCount de prueba**

   Hadoop incluye un paquete de ejemplos junto a su instalación.

```
hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-
3.3.6.jar wordcount /input/datos_prueba.txt /output
```

4. **Ver el resultado**

```
hdfs dfs -cat /output/part-r-00000
```