Guía definitiva de instalación y configuración de Hadoop 3.3.6 en clúster distribuido Ubuntu Server

1. Estructura del clúster

Rol	Hostname	IP	Usuario	Servicios
Master	master	192.168.18.101	master	NameNode, SecondaryNameNode, ResourceManager
Slave1	slave1	192.168.18.100	slave1	DataNode, NodeManager
Slave2	slave2	192.168.18.102	slave2	DataNode, NodeManager

> El siguiente procedimiento se aplica tanto para un solo esclavo (slave1) como para varios (slave2, slave3, etc.).
>
> Basta con repetir los pasos de configuración en cada nuevo nodo esclavo.

2. Requisitos previos

En todos los nodos (master y esclavos):

```
sudo apt update
sudo apt install -y openjdk-8-jdk ssh rsync
```

Verificar instalación de Java:

```
java -version
```

Debe mostrar una versión 1.8 o superior.

3. Configuración de red

Editar el archivo `/etc/hosts` en **todos los nodos**:

```
sudo nano /etc/hosts
```

Agregar las líneas:

```
127.0.0.1   localhost
192.168.18.101   master
192.168.18.100   slave1
192.168.18.102   slave2
```

Probar conectividad:

```
ping -c1 master
ping -c1 slave1
ping -c1 slave2
```

4. Creación de usuarios

Cada servidor debe tener su propio usuario, con el mismo nombre de host para claridad.

- En master → usuario `master`
- En slave1 → usuario `slave1`

- En slave2 → usuario `slave2`

---

5. Instalación de Hadoop

En cada nodo:

```
cd ~
wget https://downloads.apache.org/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz
tar -xzf hadoop-3.3.6.tar.gz
mv hadoop-3.3.6 hadoop
```

---

6. Configuración de variables de entorno

Editar `~/.bashrc` en cada nodo y agregar al final:

```
export HADOOP_HOME=/home/$(whoami)/hadoop
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/bin
```

Aplicar y verificar:

```
source ~/.bashrc
hadoop version
```

---

7. Configuración del Master

Editar los siguientes archivos en `/home/master/hadoop/etc/hadoop/`:

core-site.xml

```
<configuration>
 <property>
  <name>fs.defaultFS</name>
  <value>hdfs://master:9000</value>
 </property>
</configuration>
```

hdfs-site.xml

```
<configuration>
 <property>
  <name>dfs.replication</name>
  <value>2</value>
 </property>

 <property>
  <name>dfs.namenode.name.dir</name>
  <value>file:/hadoopdata/namenode</value>
 </property>

 <property>
```

```
    <name>dfs.datanode.data.dir</name>
    <value>file:/hadoopdata/datanode</value>
  </property>
</configuration>
```

mapred-site.xml

```
<configuration>
  <property>
    <name>mapreduce.framework.name</name>
    <value>yarn</value>
  </property>

  <property>
    <name>mapreduce.application.classpath</name>
    <value>
/home/master/hadoop/etc/hadoop,
/home/master/hadoop/share/hadoop/common/*,
/home/master/hadoop/share/hadoop/common/lib/*,
/home/master/hadoop/share/hadoop/hdfs/*,
/home/master/hadoop/share/hadoop/hdfs/lib/*,
/home/master/hadoop/share/hadoop/mapreduce/*,
/home/master/hadoop/share/hadoop/yarn/*,
/home/master/hadoop/share/hadoop/yarn/lib/*
    </value>
  </property>
</configuration>
```

yarn-site.xml

```
<configuration>
  <property>
    <name>yarn.nodemanager.aux-services</name>
    <value>mapreduce_shuffle</value>
  </property>

  <property>
    <name>yarn.resourcemanager.hostname</name>
    <value>master</value>
  </property>
</configuration>
```

hadoop-env.sh

```
export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64/jre
```

---

8. Archivo de nodos (workers)

Editar `/home/master/hadoop/etc/hadoop/workers`:

```
slave1
slave2
```

---

9. Preparación de directorios

En el master:

```
sudo mkdir -p /hadoopdata/namenode /hadoopdata/datanode
sudo chown -R master:master /hadoopdata
```

En cada nodo esclavo:

```
sudo mkdir -p /hadoopdata/namenode /hadoopdata/datanode
sudo chown -R $(whoami):$(whoami) /hadoopdata
```

---

10. Configuración SSH sin contraseña

En el master:

```
mkdir -p ~/.ssh && chmod 700 ~/.ssh
cat > ~/.ssh/config <<'EOF'
Host slave1
  HostName 192.168.18.100
  User slave1
  StrictHostKeyChecking accept-new

Host slave2
  HostName 192.168.18.102
  User slave2
  StrictHostKeyChecking accept-new
EOF
chmod 600 ~/.ssh/config
```

Generar y distribuir claves:

```
[ -f ~/.ssh/id_rsa ] || ssh-keygen -t rsa -P ""
ssh-copy-id slave1
ssh-copy-id slave2
```

Prueba de conexión:

```
ssh slave1 'hostname && whoami'
ssh slave2 'hostname && whoami'
```

---

11. Formateo del NameNode

En el master:

```
hdfs namenode -format
```

---

12. Sincronización de configuración

Enviar configuración a esclavos:

```
cd ~/hadoop/etc/hadoop
for f in core-site.xml hdfs-site.xml yarn-site.xml mapred-site.xml hadoop-env.sh; do
  scp "$f" slave1:/home/slave1/hadoop/etc/hadoop/;
  scp "$f" slave2:/home/slave2/hadoop/etc/hadoop/;
done
```

---

13. Inicio de servicios

En el master:

```
start-dfs.sh
start-yarn.sh
```

Verificar:

```
jps
ssh slave1 jps
ssh slave2 jps
```

Servicios esperados:

Master

```
NameNode
SecondaryNameNode
ResourceManager
```

Esclavos

```
DataNode
NodeManager
```

---

14. Interfaz Web

Servicio	URL	Descripción
NameNode	http://192.168.18.101:9870	Estado general del HDFS
ResourceManager	http://192.168.18.101:8088	Gestión de trabajos YARN
DataNode (slave1)	http://192.168.18.100:9864	Estado del DataNode
DataNode (slave2)	http://192.168.18.102:9864	Estado del DataNode
NodeManager	http://192.168.18.100:8042	Tareas locales YARN

---

15. Verificación de HDFS

```
hdfs dfs -mkdir -p /user/master/input
echo "hadoop mapreduce yarn test" > texto1.txt
echo "bigdata cluster system processing" > texto2.txt
hdfs dfs -put texto1.txt texto2.txt /user/master/input/
hdfs dfs -ls /user/master/input
```

---

16. Ejemplo MapReduce: WordCount

1. Ejecutar el trabajo:

```
hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.6.jar wordcount /user/master/input /user/master/output
```

1. Verificar resultados:

```
hdfs dfs -cat /user/master/output/part-r-00000
```

Salida esperada:

```
bigdata 1
cluster 2
distributed 1
hadoop 3
hdfs 1
mapreduce 3
processing 1
system 1
test 1
yarn 2
```

---

17. Detener servicios

En el master:

```
stop-yarn.sh
stop-dfs.sh
```

Conclusión

El clúster Hadoop 3.3.6 queda completamente operativo con:

- Comunicación entre nodos verificada vía `/etc/hosts`.
- SSH sin contraseña configurado.
- HDFS y YARN funcionando de forma distribuida.
- Ejecución exitosa de trabajos MapReduce.
- Interfaces web de monitoreo accesibles.
- Facilidad para escalar con nuevos esclavos repitiendo el procedimiento.