Big Data

Hechos del Big Data

- Cada 2 días creamos tanta información como lo hicimos desde el principio hasta 2003.
- Más del 90% de todos los datos en el mundo fueron creados en los últimos 2 años.
- Se espera que para 2020 la cantidad de información digital en existencia haya aumentado de 3.2 zettabytes hoy a 40 zettabytes.
- La cantidad total de datos capturados y almacenados por la industria se duplica cada 1,2 años.

- Cada minuto enviamos 204 millones de correos electrónicos, generamos 1,8 millones de me gusta de Facebook, enviamos 278 mil tweets y cargamos 200,000 fotos a Facebook.
- Solo Google procesa en promedio más de 40 mil consultas de búsqueda por segundo, lo que hace que supere los 3,5 mil millones en un solo día.

- Alrededor de 100 horas de video se suben a YouTube cada minuto y le tomará alrededor de 15 años ver cada video subido por los usuarios en un día.
- Si quemó todos los datos creados en un solo día en DVD, podría apilarlos uno encima del otro y alcanzar la luna - dos veces.
- Se cree que AT&T tiene el mayor volumen de datos del mundo en una única base de datos: su base de datos de registros telefónicos tiene un tamaño de 312 terabytes y contiene casi 2 billones de filas.

- 570 nuevos sitios web surgen cada minuto de cada día.
- Para el 2015, se crearán 1.9 millones de empleos de TI en los EE. UU. Para llevar a cabo proyectos de big data. Cada uno de ellos contará con el respaldo de 3 nuevos empleos creados fuera de TI, lo que significa un total de 6 millones de nuevos empleos gracias a Big Data.
- Los centros de datos de hoy ocupan un área de terreno de casi 6.000 campos de fútbol.

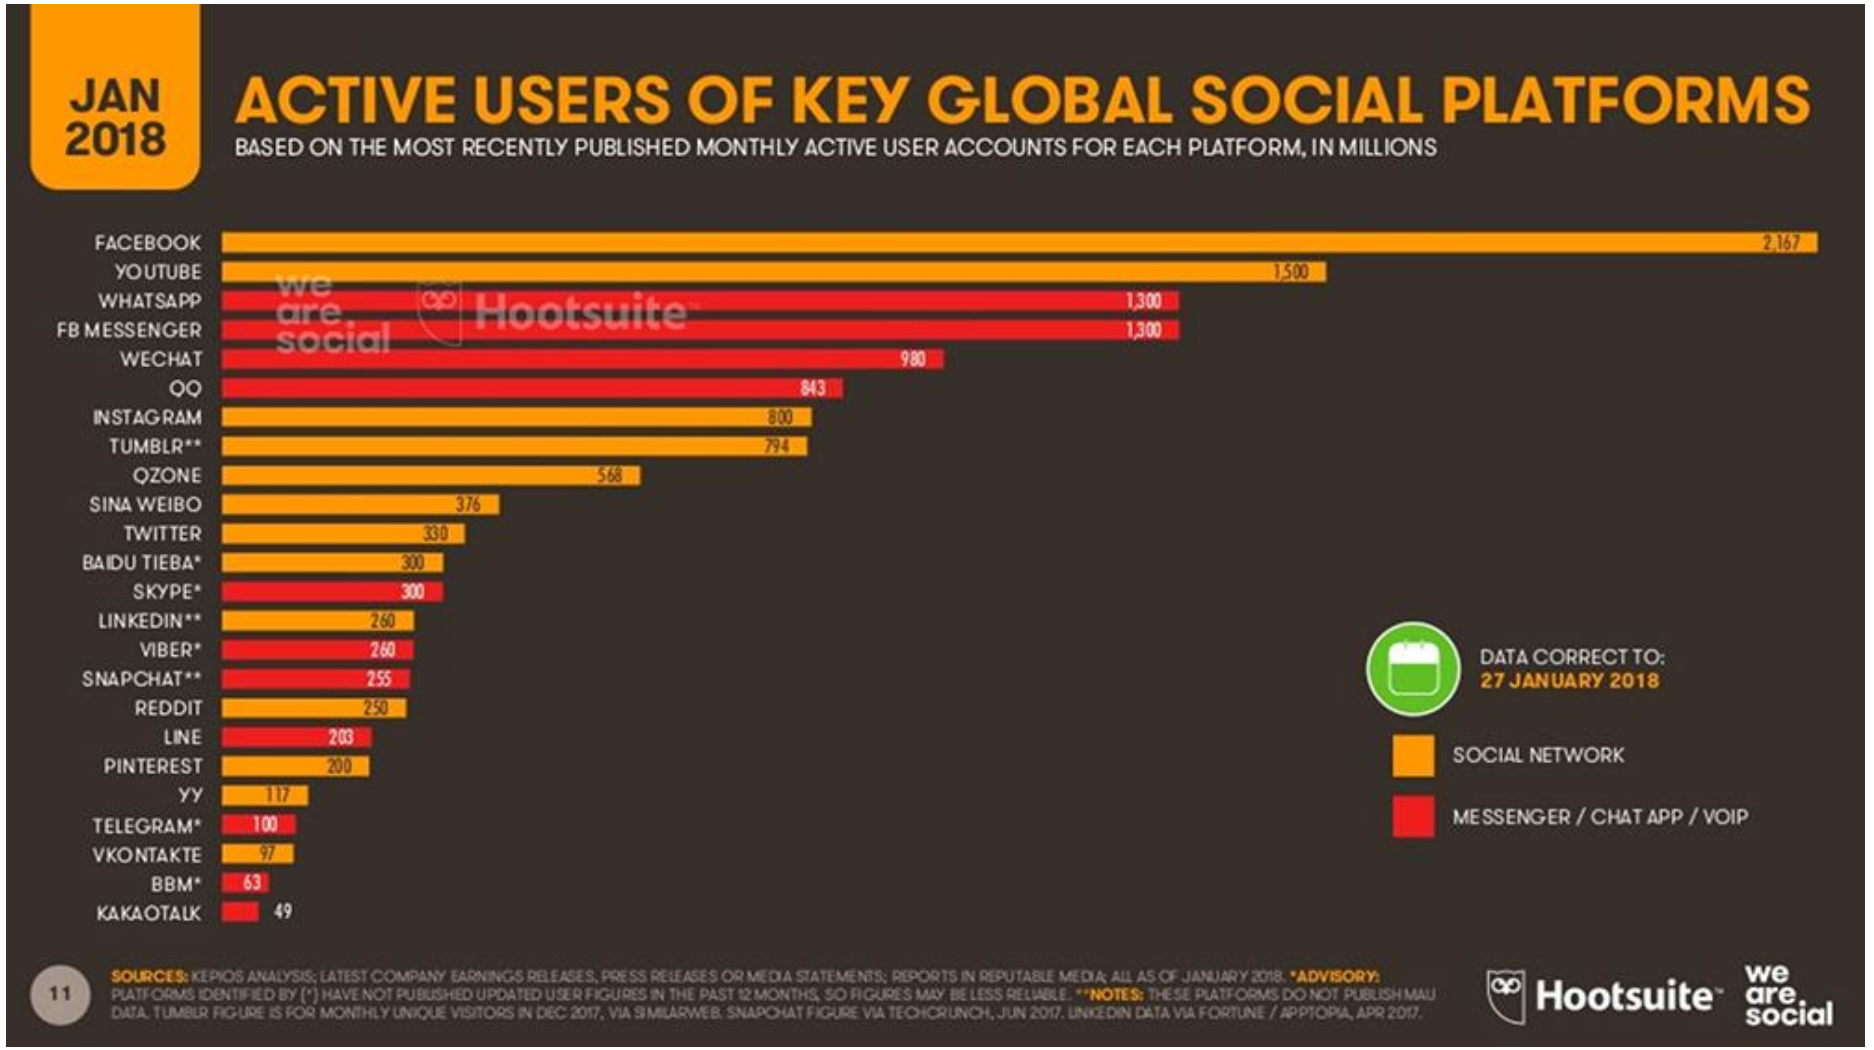
- Entre ellas, las compañías que monitorean Twitter para medir el "sentimiento" analizan 12 terabytes de tweets todos los días.
- La cantidad de datos transferidos a través de redes móviles aumentó en un 81% a 1.5 exabytes (1.5 mil millones de gigabytes) por mes entre 2012 y 2014. El video representa el 53% de ese total.
- Se piensa que la NSA analiza el 1.6% de todo el tráfico global de Internet: alrededor de 30 petabytes (30 millones de gigabytes) por día.

El tiempo del Big Data

- En 2013 un reporte de McKinsey afirmo que en el are de Ciencias de Datos, será un catalizador del crecimiento económico.
- También identifico una nueva oportunidad la contribución del despegue de la era del Big Data que viene continuamente y velozmente.

- El numero de líneas móviles alcanzan a los 5000 millones en 2017, perlo las tarjetas SIM se elevaron a 7800 millones, se menciona en el informe anual *Mobile Economy* de la GSMA.
- El estudio prevé que se añadirán casi mil millones de usuarios de telefonía móvil en 2025, alcanzando los 5.900 millones de suscriptores, lo que equivale al 71% de la población mundial prevista para ese momento.

- Estos teléfonos son una gran fuente de datos del Big Data, que contribuyen todos los días, y en Facebook en 2017 tiene en el mundo 2167 usuario en el mundo con mas de 30 mil millones de contenido compartidos, Youtube tiene tres cuartas partes, con gran cantidad de videos vistos.
- Entonces se tienen proyecciones grandes de datos alrededor del 40% de datos globales al año y 5% de gastos globales de TI, la que impulsa a la Ciencia de Datos.


JAN 2018
ACTIVE USERS OF KEY GLOBAL SOCIAL PLATFORMS
BASED ON THE MOST RECENTLY PUBLISHED MONTHLY ACTIVE USER ACCOUNTS FOR EACH PLATFORM, IN MILLIONS
FACEBOOK 2,167
YOUTUBE 1,500
WHATSAPP 1,300
FB MESSENGER 1,300
WECHAT 980
QQ 843
INSTAGRAM 800
TUMBLR** 794
QZONE 568
SINA WEIBO 376
TWITTER 330
BAIDU TIEBA* 300
SKYPE* 300
LINKEDIN** 260
VIBER* 260
SNAPCHAT** 255
REDDIT 250
LINE 203
PINTEREST 200
YY 117
TELEGRAM* 100
VKONTAKTE 97
BBM* 63
KAKAOTALK 49
we are social
Hootsuite
DATA CORRECT TO:
27 JANUARY 2018
SOCIAL NETWORK
MESSENGER / CHAT APP / VOIP
11
SOURCES: KEPIOS ANALYSIS; LATEST COMPANY EARNINGS RELEASES, PRESS RELEASES OR MEDIA STATEMENTS; REPORTS IN REPUTABLE MEDIA; ALL AS OF JANUARY 2018. *ADVISORY: PLATFORMS IDENTIFIED BY (*) HAVE NOT PUBLISHED UPDATED USER FIGURES IN THE PAST 12 MONTHS, SO FIGURES MAY BE LESS RELIABLE. **NOTES: THESE PLATFORMS DO NOT PUBLISH MAU DATA. TUMBLR FIGURE IS FOR MONTHLY UNIQUE VISITORS IN DEC 2017, VIA SIMILARWEB. SNAPCHAT FIGURE VIA TECHCRUNCH, JUN 2017. LINKEDIN DATA VIA FORTUNE / APPTOPIA, APR 2017.
Hootsuite
we are social

Historia

- 1965. Se proyecta el **primer *data center*** en Estados Unidos.
- 1989. Erik Larson habla por primera vez de **Big Data** en el sentido que conocemos la expresión hoy en día.
- 1991. **Nace internet**, a la postre, la gran revolución de la recolección, almacenamiento y análisis de datos.
- 1996. Los precios del **almacenamiento de datos** empiezan a ser accesibles con un coste eficiente en lo que es una de las grandes revoluciones en la historia del big data.

- 1997. **Google** lanza su sistema de búsqueda en internet.
- 1999. El término Big Data es analizado por primera vez en un **estudio académico**.
- 2001. Doug Laney, de Gartner, define **las 3 V's del Big Data.**
- 2005. Nace la Web 2.0, una web donde predomina el contenido creado por los usuarios. Este mismo año se crea Hadoop, un entorno de trabajo Big Data de software libre.

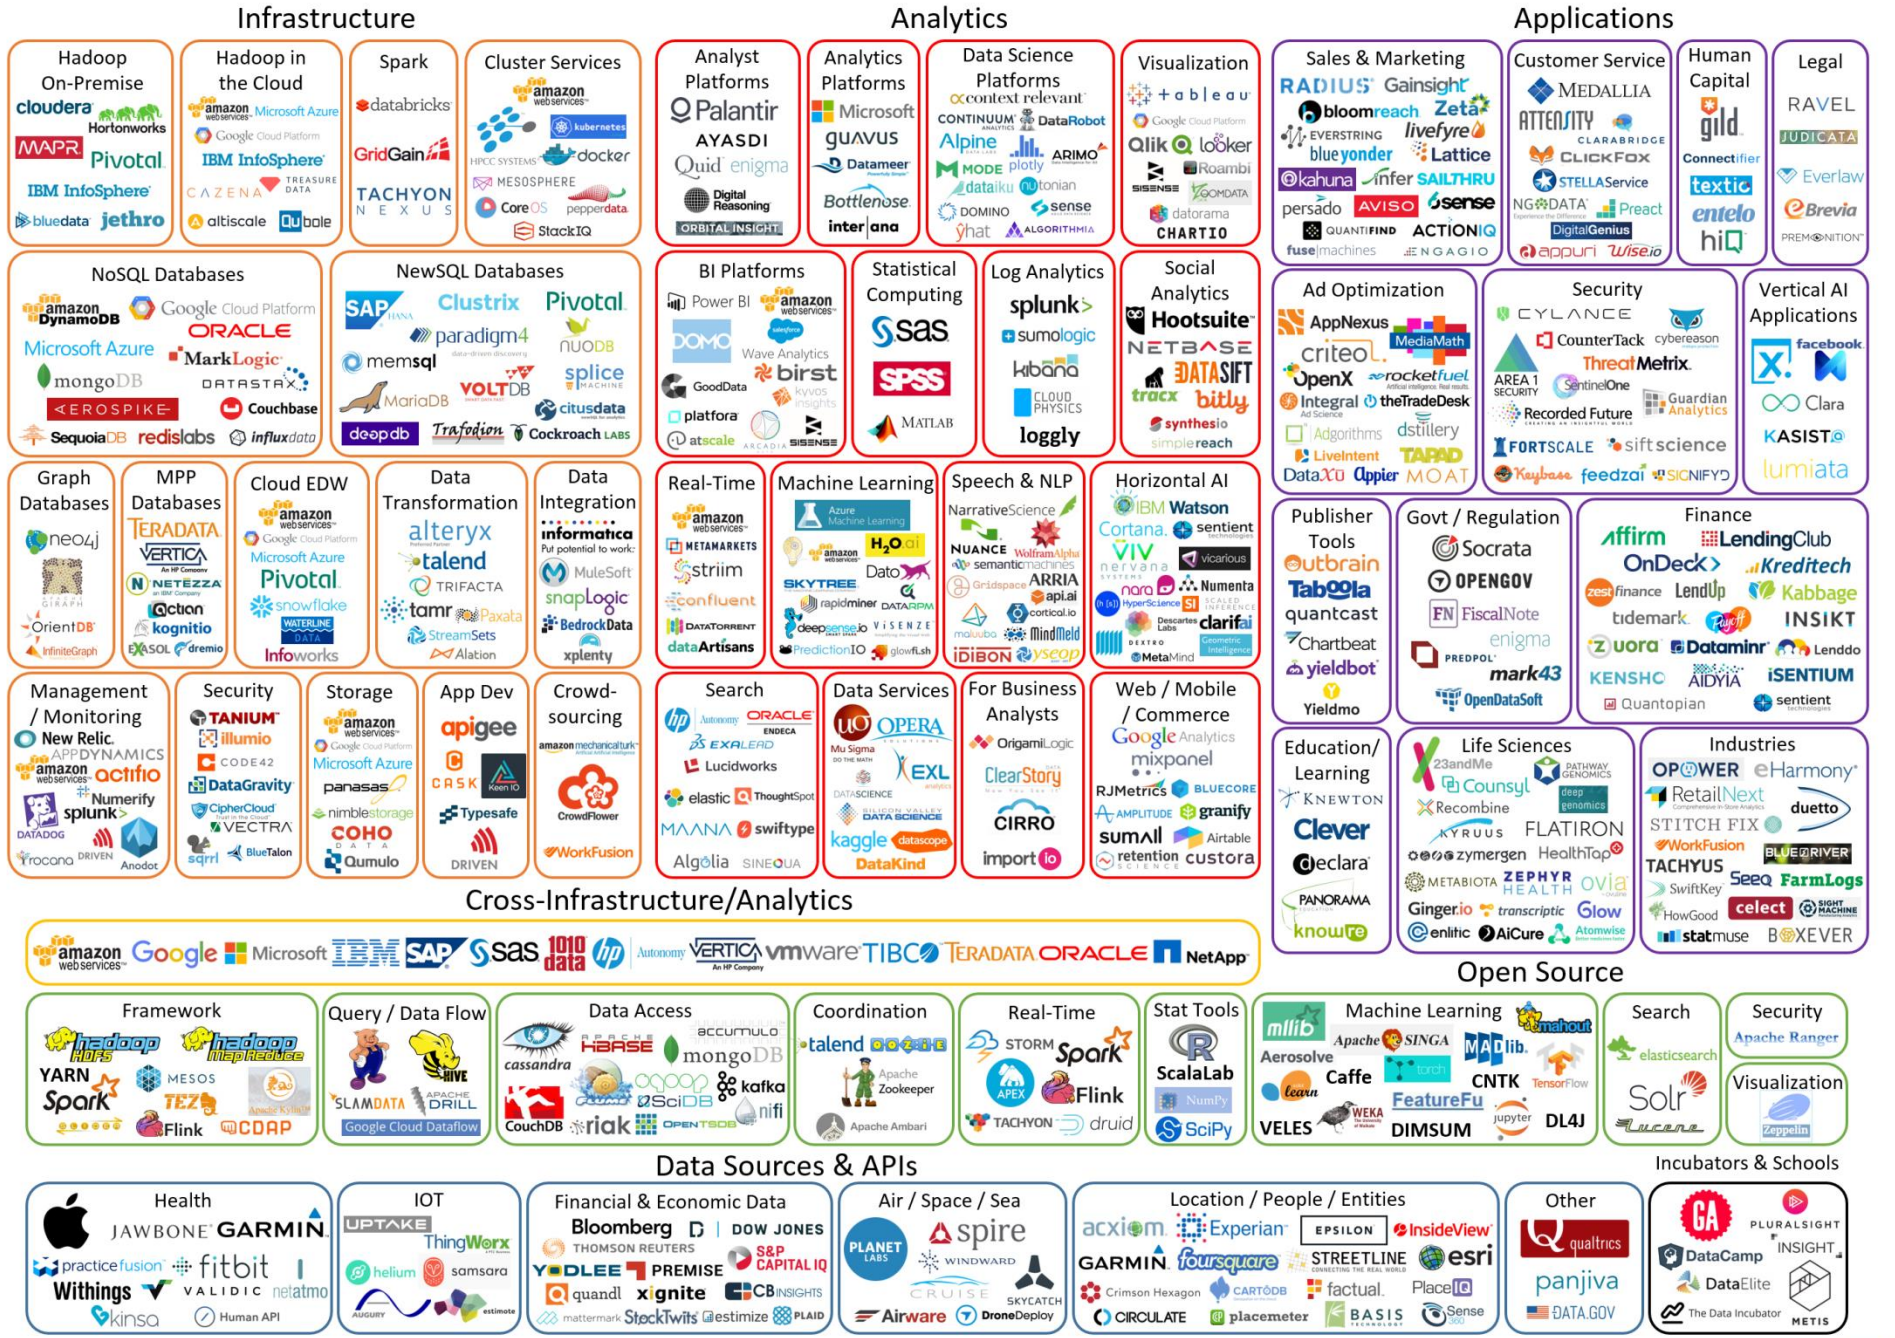
- 2007. La revista Wired publica un artículo que lleva el concepto de **Big Data.**
- 2016. El Big Data se convierte en la **palabra de moda**. Se generaliza la contratación de expertos en Big Data, el Machine Learning llega a las fábricas y el Internet de las Cosas empieza a impregnarlo todo.
- **Futuro**. ¿Qué nos deparará el futuro? Muy difícil de pronosticar, pero seguramente un aumento de datos y la consiguiente necesidad de tecnología para recogerlos, adaptarlos, almacenarlos y analizarlos. La **computación cuántica** está a la vuelta de la esquina y la historia del Big Data sigue avanzando.

Que es Big Data

Big data es un término que describe el gran volumen de datos – estructurados y no estructurados – que inundan una empresa todos los días. Pero no es la cantidad de datos lo importante. Lo que importa es lo que las organizaciones hacen con los datos. El Big Data puede ser analizado para obtener comprensión que conlleven a mejores decisiones y acciones de negocios estratégicas.

SAS

Big Data Landscape 2016 (Version 3.0)



Last Updated 3/23/2016

© Matt Turck (@mattturck), Jim Hao (@jimrhao), & FirstMark Capital (@firstmarkcap)

FIRSTMARK

BIG DATA LANDSCAPE 2017



BIG DATA & AI LANDSCAPE 2018

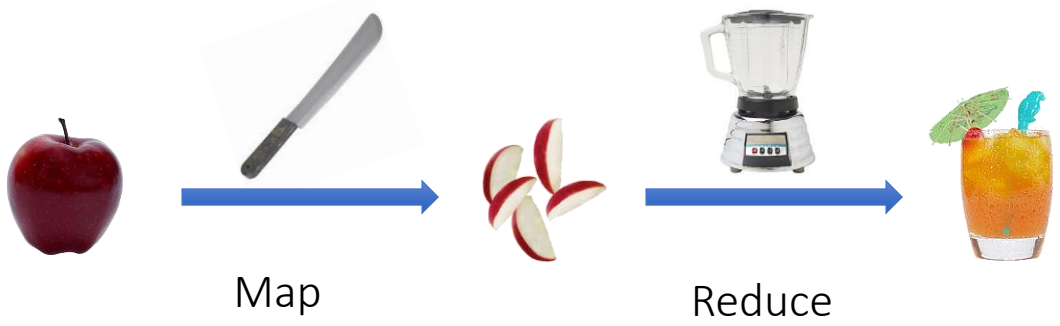


© Matt Turck (@mattturck), Demi Obayomi (@demi_obayomi), & FirstMark (@firstmarkcap)

FIRSTMARK
EARLY STAGE VENTURE CAPITAL

WordCount

Ejemplo



Ejemplo WordCount

```
map(String input_key, String input_value):
  // input_key: document name
  // input_value: document contents
  for each word w in input_value:
    EmitIntermediate(w, "1");
```

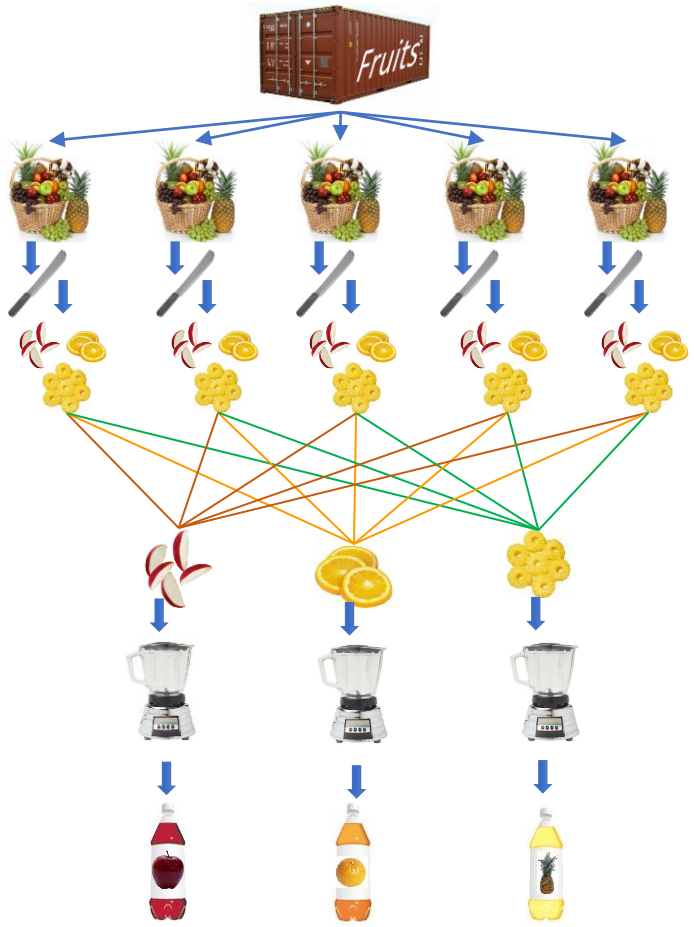
<“Sam”, “1”>, <“Apple”, “1”>, <“Sam”, “1”>,
<“Mom”, “1”>, <“Sam”, “1”>, <“Mom”, “1”>,

```
reduce(String output_key, Iterator intermediate_values):
  // output_key: a word
  // output_values: a list of counts
  int result = 0;
  for each v in intermediate_values:
    result += ParseInt(v);
  Emit(AsString(result));
```

<“Sam” , [“1”,”1”,”1”]>, <“Apple” , [“1”]>,
<“Mom” , [“1”, “1”]>

“3”
“1”
“2”

- Implementación Paralela

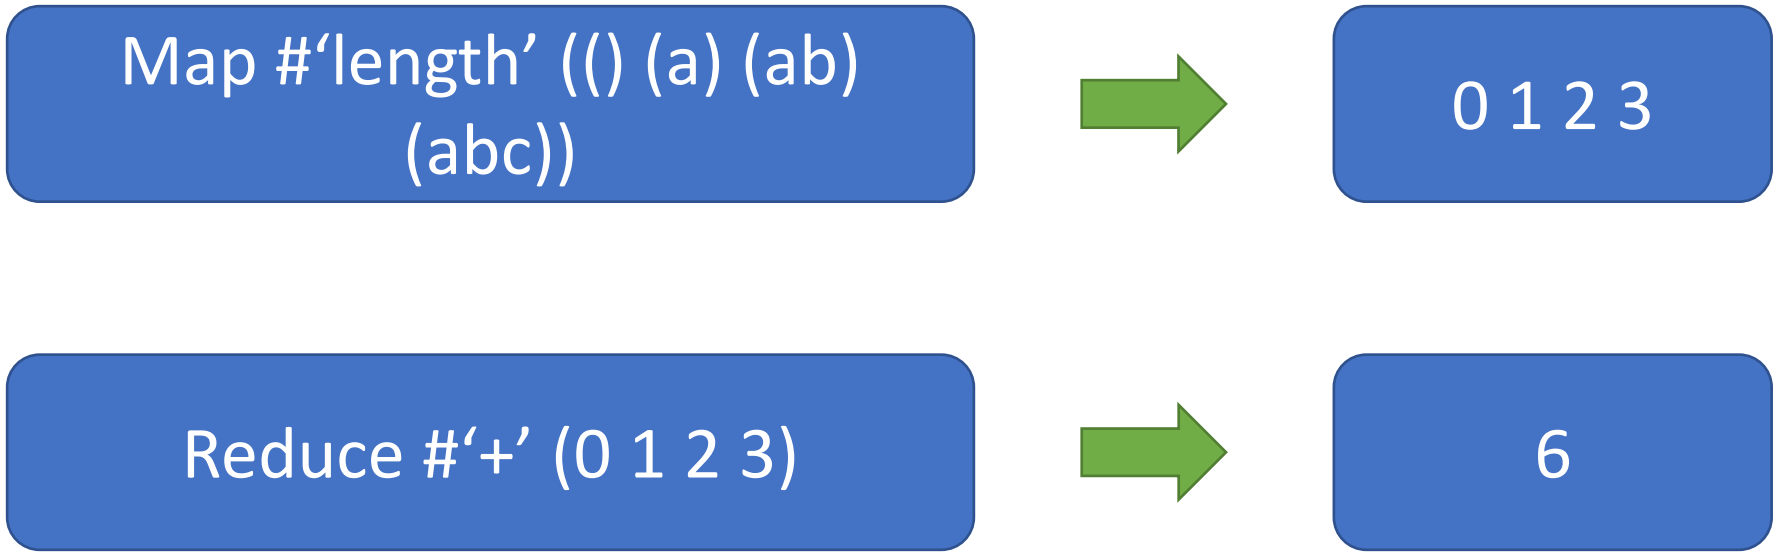


MapReduce

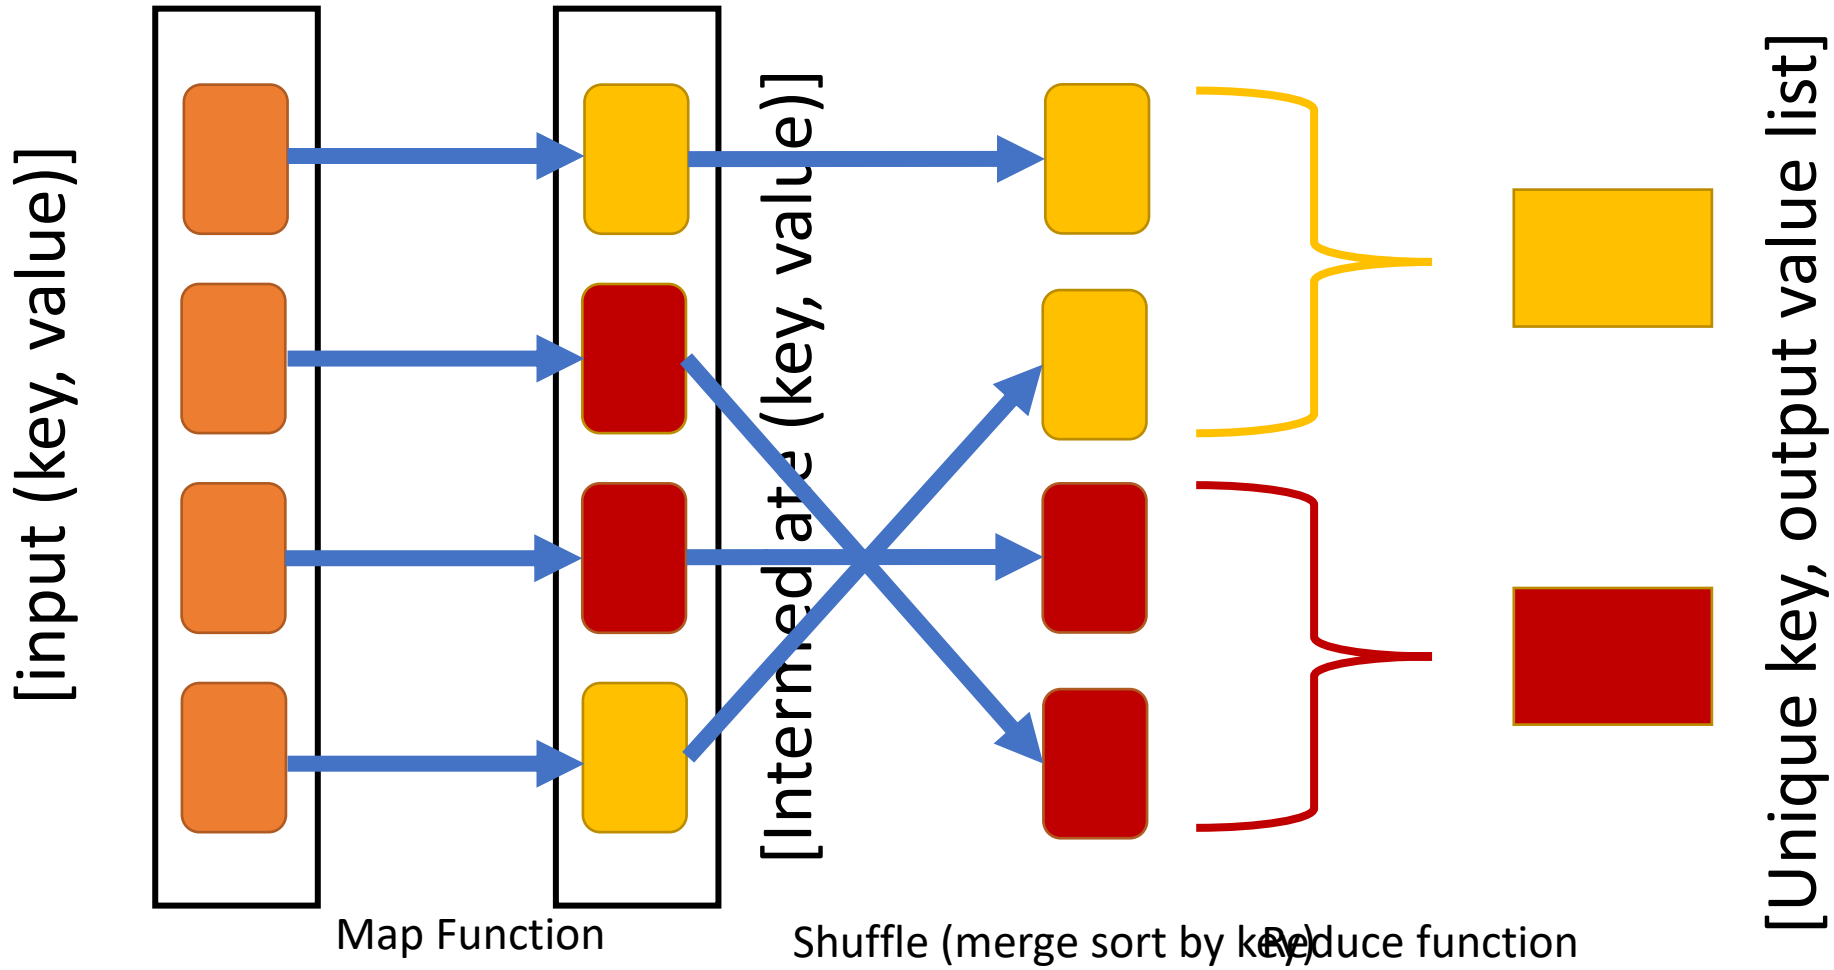
- MapReduce es una infraestructura de la programacion funcionl
  - Interfaz de programación simple: Map + Reduce
  - Implementación distribuida que oculta todos los detalles desordenados. Tolerancia a fallos Programación de E / S paralelización

Modelo de Programacion

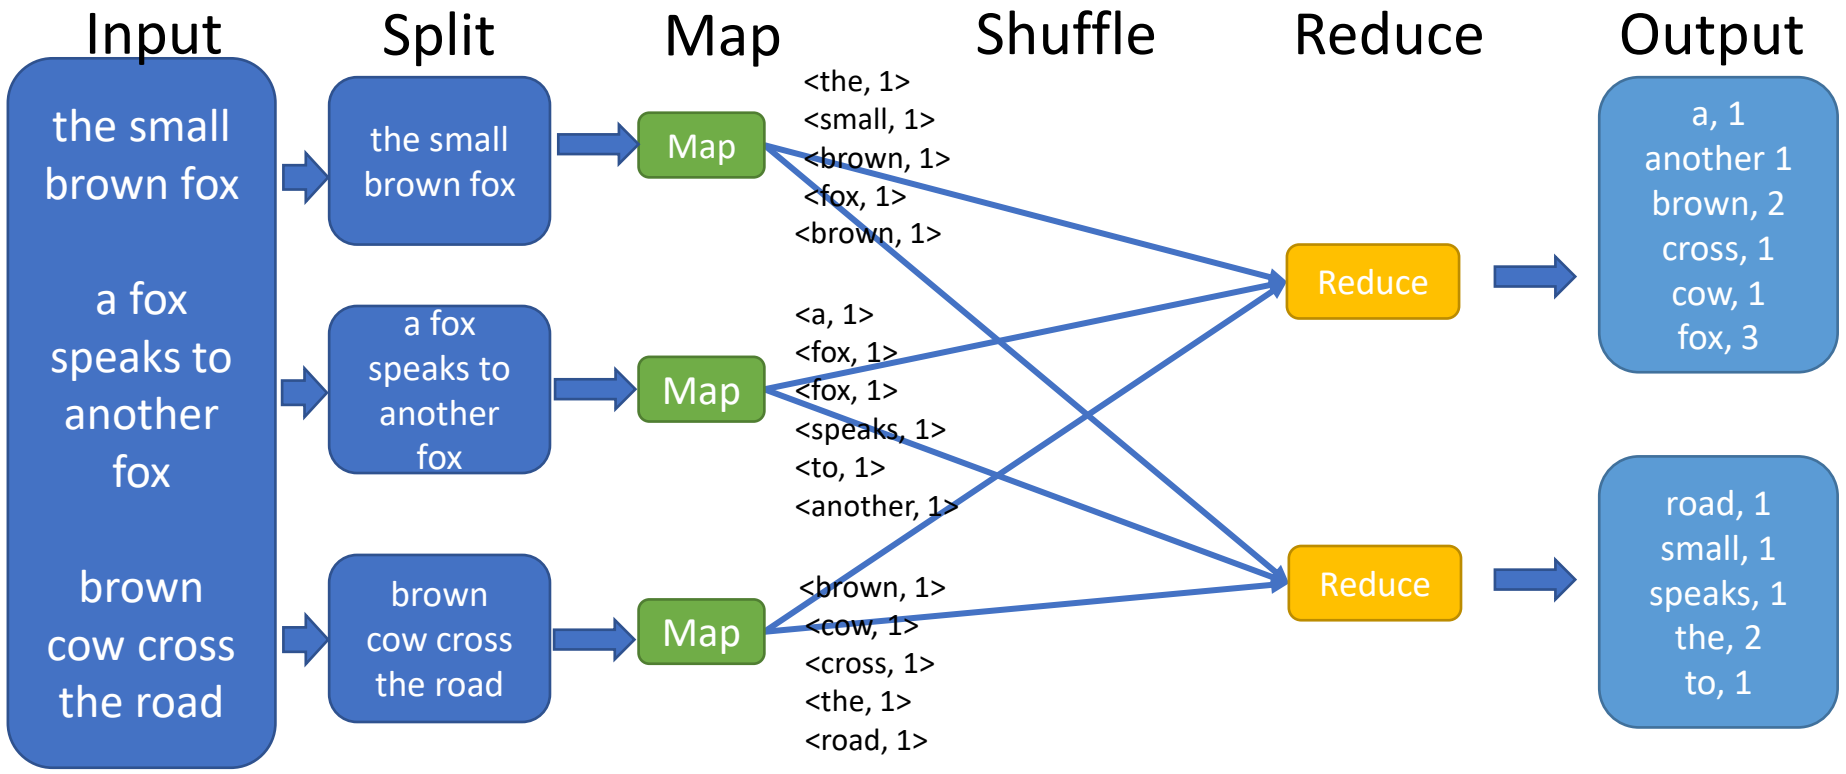
- Inspirado en map y reduce funciones de Lisp y otros languages de programacion funcional
- Lisp:

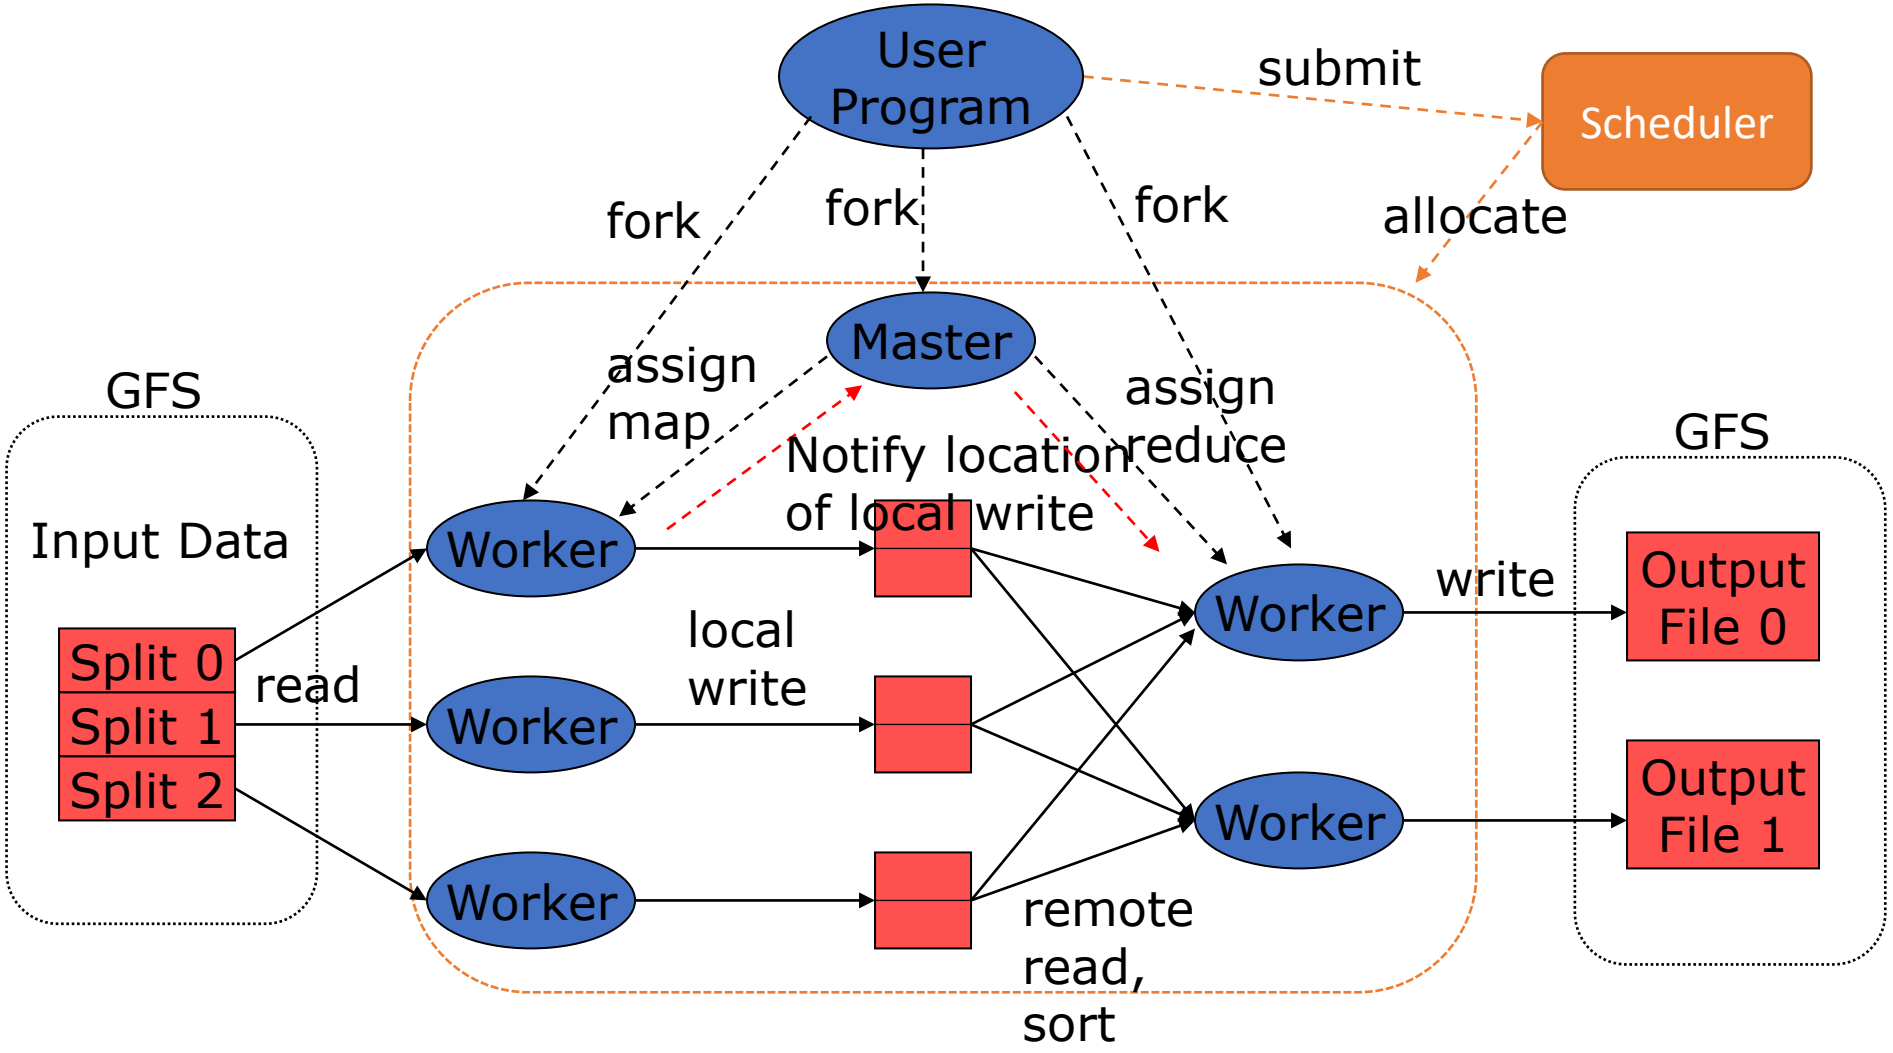


Programming Model



Ejemplo Word Count




User Program
submit
Scheduler
fork
fork
fork
allocate
Master
assign map
assign reduce
GFS
Input Data
Split 0
Split 1
Split 2
read
Worker
Worker
Worker
Notify location of local write
local write
remote read, sort
Worker
Worker
write
GFS
Output File 0
Output File 1

```
public class WordCount {
 public static class Map extends Mapper<LongWritable, Text, Text, IntWritable> {
    private final static IntWritable one = new IntWritable(1);
    private Text word = new Text();

    public void map(LongWritable key, Text value, Context context) throws IOException, InterruptedException {
        String line = value.toString();
        StringTokenizer tokenizer = new StringTokenizer(line);
        while (tokenizer.hasMoreTokens()) {
            word.set(tokenizer.nextToken());
            context.write(word, one);
 }}}
```

Mapper

```
 public static class Reduce extends Reducer<Text, IntWritable, Text, IntWritable> {

    public void reduce(Text key, Iterable<IntWritable> values, Context context)
      throws IOException, InterruptedException {
        int sum = 0;
        for (IntWritable val : values) {
            sum += val.get();
        }
        context.write(key, new IntWritable(sum));
 }}
```

Reducer

```
 public static void main(String[] args) throws Exception {
    Configuration conf = new Configuration();

        Job job = new Job(conf, "wordcount");

    job.setOutputKeyClass(Text.class);
    job.setOutputValueClass(IntWritable.class);

    job.setMapperClass(Map.class);
    job.setReducerClass(Reduce.class);

    job.setInputFormatClass(TextInputFormat.class);
    job.setOutputFormatClass(TextOutputFormat.class);

    FileInputFormat.addInputPath(job, new Path(args[0]));
    FileOutputFormat.setOutputPath(job, new Path(args[1]));

    job.waitForCompletion(true);
}}
```

Ejecutar este programa como un job de MapReduce

- MapReduce Architecture: http://cecs.wright.edu/~tkprasad/courses/cs707/L06MapReduce.ppt/
- MapReduce Presentation: http://research.google.com/archive/mapreduce-osdi04-slides/
- MapReduce Presentation: http://web.eecs.umich.edu/~mozafari/fall2015/eecs584/presentations/lecture15-a.pdf/
- Operating system support for warehouse-scale computing: https://www.cl.cam.ac.uk/~ms705/pub/thesis-submitted.pdf/
- Apache Ecosystem Pic: http://blog.agroknow.com/?cat=1
- MapReduce: http://static.googleusercontent.com/media/research.google.com/en//archive/mapreduce-osdi04.pdf/
- FlumeJava: http://pages.cs.wisc.edu/~akella/CS838/F12/838-CloudPapers/FlumeJava.pdf/
- MillWheel: http://www.vldb.org/pvldb/vol6/p1033-akidau.pdf/
- Pregel: http://web.stanford.edu/class/cs347/reading/pregel.pdf/

- Giraph: http://giraph.apache.org/
- Spark: http://spark.apache.org/
- Tez: https://tez.apache.org/
- DataFlow: http://www.vldb.org/pvldb/vol8/p1792-Akidau.pdf/
- Tensorflow: https://www.tensorflow.org/
- Apache Beam: http://incubator.apache.org/projects/beam.html
- SparkNet: https://github.com/amplab/SparkNet
- Caffe on Spark: http://yahoohadoop.tumblr.com/post/129872361846/large-scale-distributed-deep-learning-on-hadoop