

Data Analytics

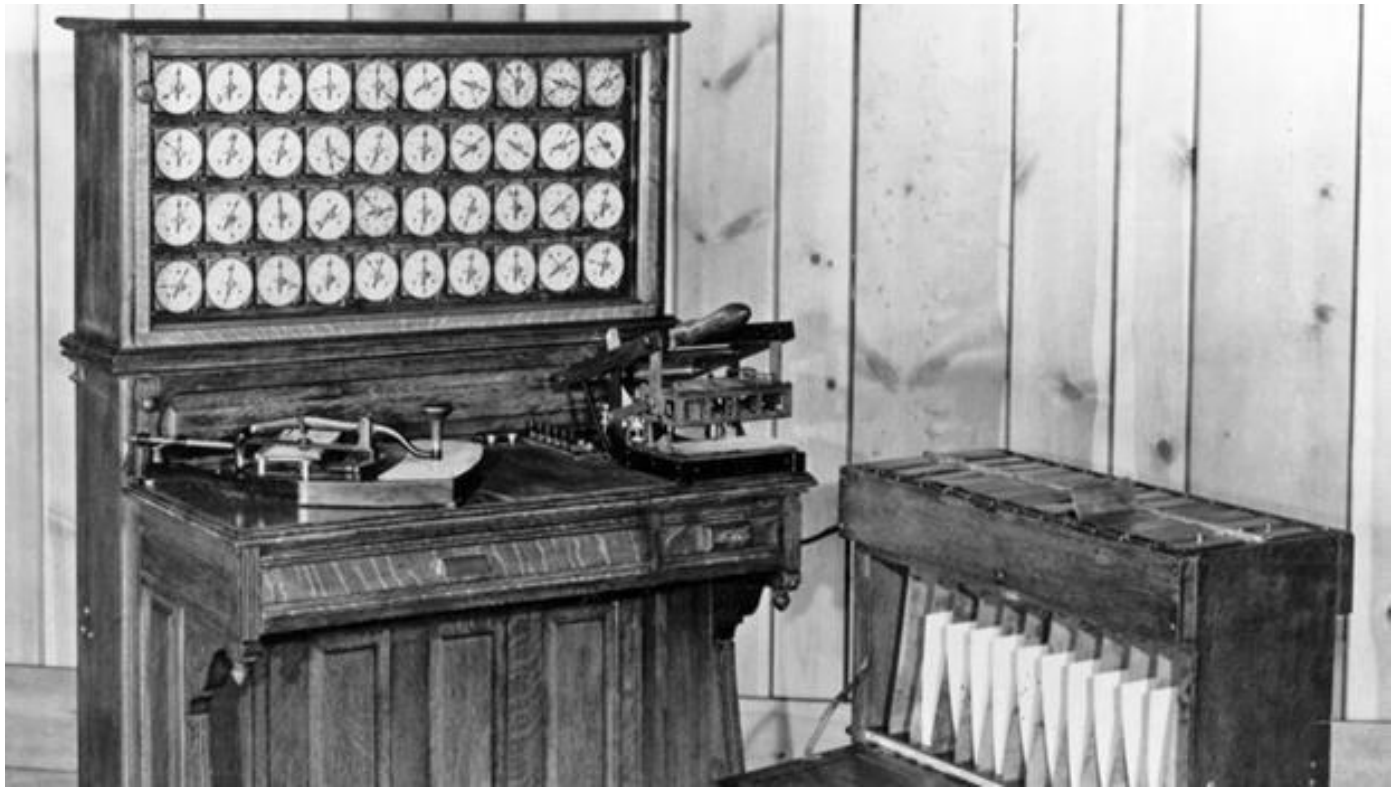
Tabulador de tarjetas perforadas

- Las primeras máquinas tabuladoras de Herman Hollerith abrieron los ojos del mundo a la idea misma de procesamiento de datos. En el camino, las máquinas también sentaron las bases de IBM.



Transformar el proceso de censo

- El tabulador de tarjetas perforadas de Herman Hollerith transformó el proceso censal y el tratamiento de la información en general a partir del censo estadounidense de 1890. La máquina era capaz de recoger y contar datos con mayor rapidez y precisión que los procesos manuales del pasado



Transformar el proceso censal

- En 1880, cuando los recién llegados inundaron Estados Unidos y la población se disparó, el censo estadounidense se convirtió en una pesadilla administrativa. El trabajo de medir y registrar la población del país, en rápido crecimiento, era enloquecedoramente lento y costoso. Los funcionarios necesitaban ocho años para terminar de elaborar el censo. Uno de ellos era Herman Hollerith, licenciado en ingeniería por la Universidad de Columbia de Nueva York a los 19 años.

Data Mining

- La minería de datos es el proceso de identificar patrones en los datos.
- La minería de datos puede implicar el uso de estadísticas, consultas a bases de datos, herramientas de visualización, programación tradicional y aprendizaje automático.

Machine learning

- El aprendizaje automático es el uso de algoritmos de reconocimiento de patrones de datos para resolver problemas. Existen dos formas principales de aprendizaje automático: supervisado y no supervisado. En el aprendizaje automático supervisado, el algoritmo examina un conjunto de datos de entrenamiento para aprender a identificar patrones. El aprendizaje no supervisado, por el contrario, no utiliza un conjunto de datos de entrenamiento.

Data visualization

- La visualización de datos es el uso de diagramas y gráficos para representar datos. Los analistas utilizan muchos gráficos diferentes para representar los datos. La clave está en saber qué gráfico utilizar en cada momento.
- Para obtener ejemplos de conjuntos de datos que se pueden utilizar con algoritmos de minería de datos y aprendizaje automático, muchos sitios web ofrecen archivos descargables. Dos de los repositorios de conjuntos de datos más utilizados son el repositorio de conjuntos de datos de la Universidad de California Irvine (UCI) y el sitio web de Kaggle.

Visual programming

- La programación visual es el proceso de especificar el procesamiento arrastrando y soltando diferentes objetos en un espacio de trabajo, en contraposición al uso de sentencias en lenguaje de programación. Este texto presenta los entornos de programación visual RapidMiner y Orange.

Business intelligence

- La inteligencia empresarial es el uso de herramientas (minería de datos, aprendizaje automático y visualización) para convertir los datos en ideas y recomendaciones prácticas.
- La mayoría de los lenguajes de programación modernos ofrecen bibliotecas de software que los programadores pueden utilizar para crear soluciones de minería de datos y aprendizaje automático. Debido a su popularidad y uso común, este texto hace un uso extensivo de Python.

Data cleansing

- El primer paso que los analistas de datos realizan con los datos nuevos es limpiar los datos para eliminar registros duplicados, resolver valores nulos o no numéricos (NaN), identificar valores atípicos, etc. Un analista puede limpiar los datos de muchas formas, que pueden incluir el uso de Excel, un lenguaje de programación o incluso una herramienta de terceros..

Data quality

La calidad de los datos es una medida de la idoneidad de los datos para su uso. Los analistas de datos calculan la calidad teniendo en cuenta factores como:
Precisión: el grado en que los datos representan correctamente los valores subyacentes del mundo real, como que todas las temperaturas de un sensor estén en el rango correcto.
Exhaustividad: el grado en que los datos representan todos los valores requeridos, por ejemplo, un conjunto de datos que debería contener una hora de datos, para un sensor que informa cada segundo, con el 100% de los valores de datos..

Data quality

- Coherencia: el grado en que valores de datos similares o relacionados se alinean en todo el conjunto de datos, como por ejemplo que cada aparición de una dirección tenga el mismo código postal.
- Conformidad: el grado en que los valores de los datos se ajustan a las normas empresariales, por ejemplo, la empresa medirá y almacenará los valores de los sensores en intervalos de 1 segundo..

Data clustering

- La agrupación de datos es el proceso de agrupar elementos de conjuntos de datos relacionados en uno o más clústeres. El clustering utiliza el aprendizaje automático no supervisado, para el que el algoritmo subyacente no utiliza un conjunto de datos de entrenamiento..

Data classification

- La clasificación de datos es el proceso de asignar datos a grupos coincidentes (categorías), como que un tumor sea benigno o maligno, que un correo electrónico sea válido o spam, o que una transacción sea legítima o fraudulenta.

Predictive analytics

- El análisis predictivo es el uso de datos para predecir lo que ocurrirá en el futuro.

Data association

- La asociación de datos es el proceso de identificar relaciones clave entre variables. Uno de los problemas de asociación de datos más conocidos es el análisis de la cesta de la compra, que examina los artículos de la cesta de la compra de un cliente para determinar si la presencia de un artículo en la cesta (llamado antecedente) influye en la adición de un segundo artículo (llamado consecuente).

Data Mining Versus Machine Learning

- La minería de datos es el proceso de identificar patrones que existen en los datos. Una vez identificados los patrones, los analistas de datos pueden aplicarlos a otros conjuntos de datos. Piense en la «minería» propiamente dicha como la búsqueda de patrones de datos, en contraposición al uso posterior de los patrones. El proceso de minería de datos puede implicar el uso de estadísticas, consultas a bases de datos, herramientas de visualización, programación tradicional y aprendizaje automático.
- El aprendizaje automático se define como el uso de algoritmos de reconocimiento de patrones de datos que permiten a un programa resolver problemas, como la agrupación, la categorización, el análisis predictivo y la asociación de datos, sin necesidad de instrucciones de programación explícitas paso a paso que indiquen al algoritmo cómo realizar las tareas. De este modo, las soluciones de aprendizaje automático pueden resolver problemas complejos utilizando los datos para impulsar el descubrimiento, mediante el uso de sólo unas pocas líneas de código.

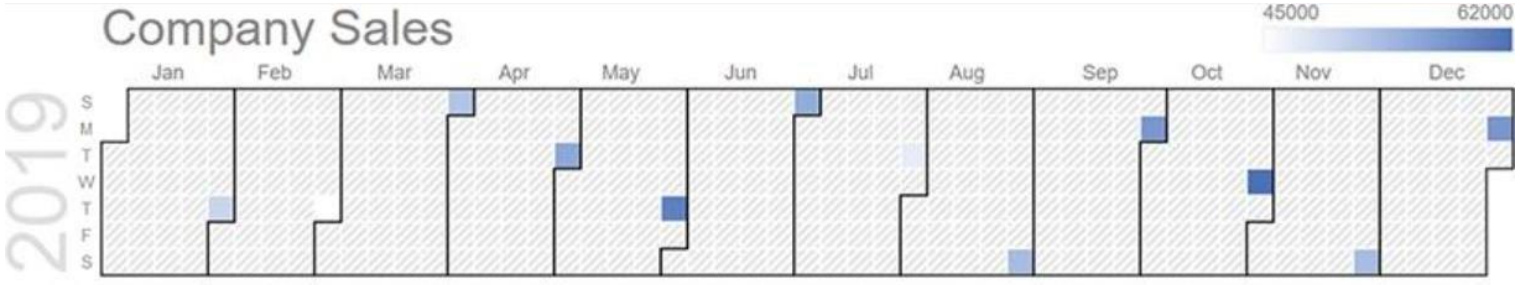
Data Mining Versus Data Science

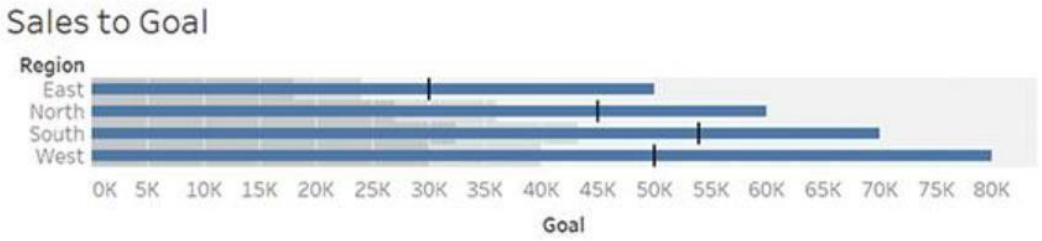
- La minería de datos es el proceso de identificar patrones que existen en los datos.
- La ciencia de datos es el uso de estadísticas, programación, métodos científicos y aprendizaje automático para extraer conocimientos de un conjunto de datos. Como puede ver, las definiciones de minería de datos y ciencia de datos son muy similares. De hecho, ambos términos suelen utilizarse indistintamente.
- Un científico de datos, por tanto, es una persona que analiza e interpreta datos. Una vez más, los términos científico de datos y analista de datos son bastante similares. Ambos utilizan herramientas de minería de datos para obtener información sobre uno o varios conjuntos de datos..

Data Mining Versus Statistics

- La minería de datos es el proceso de identificar patrones que existen en los datos.
- La estadística es la recopilación, el análisis, la modelización y la presentación de datos. La estadística es uno de los componentes de la minería de datos, es decir, una de las herramientas del analista de datos. El conocimiento y la comprensión de la estadística ayudarán al analista de datos a entender mejor el procesamiento entre bastidores de muchos de los algoritmos de minería de datos y aprendizaje automático que se presentan en este texto. Dicho esto, la buena noticia es que no es necesario ser estadístico para utilizar las herramientas..

Data Visualization

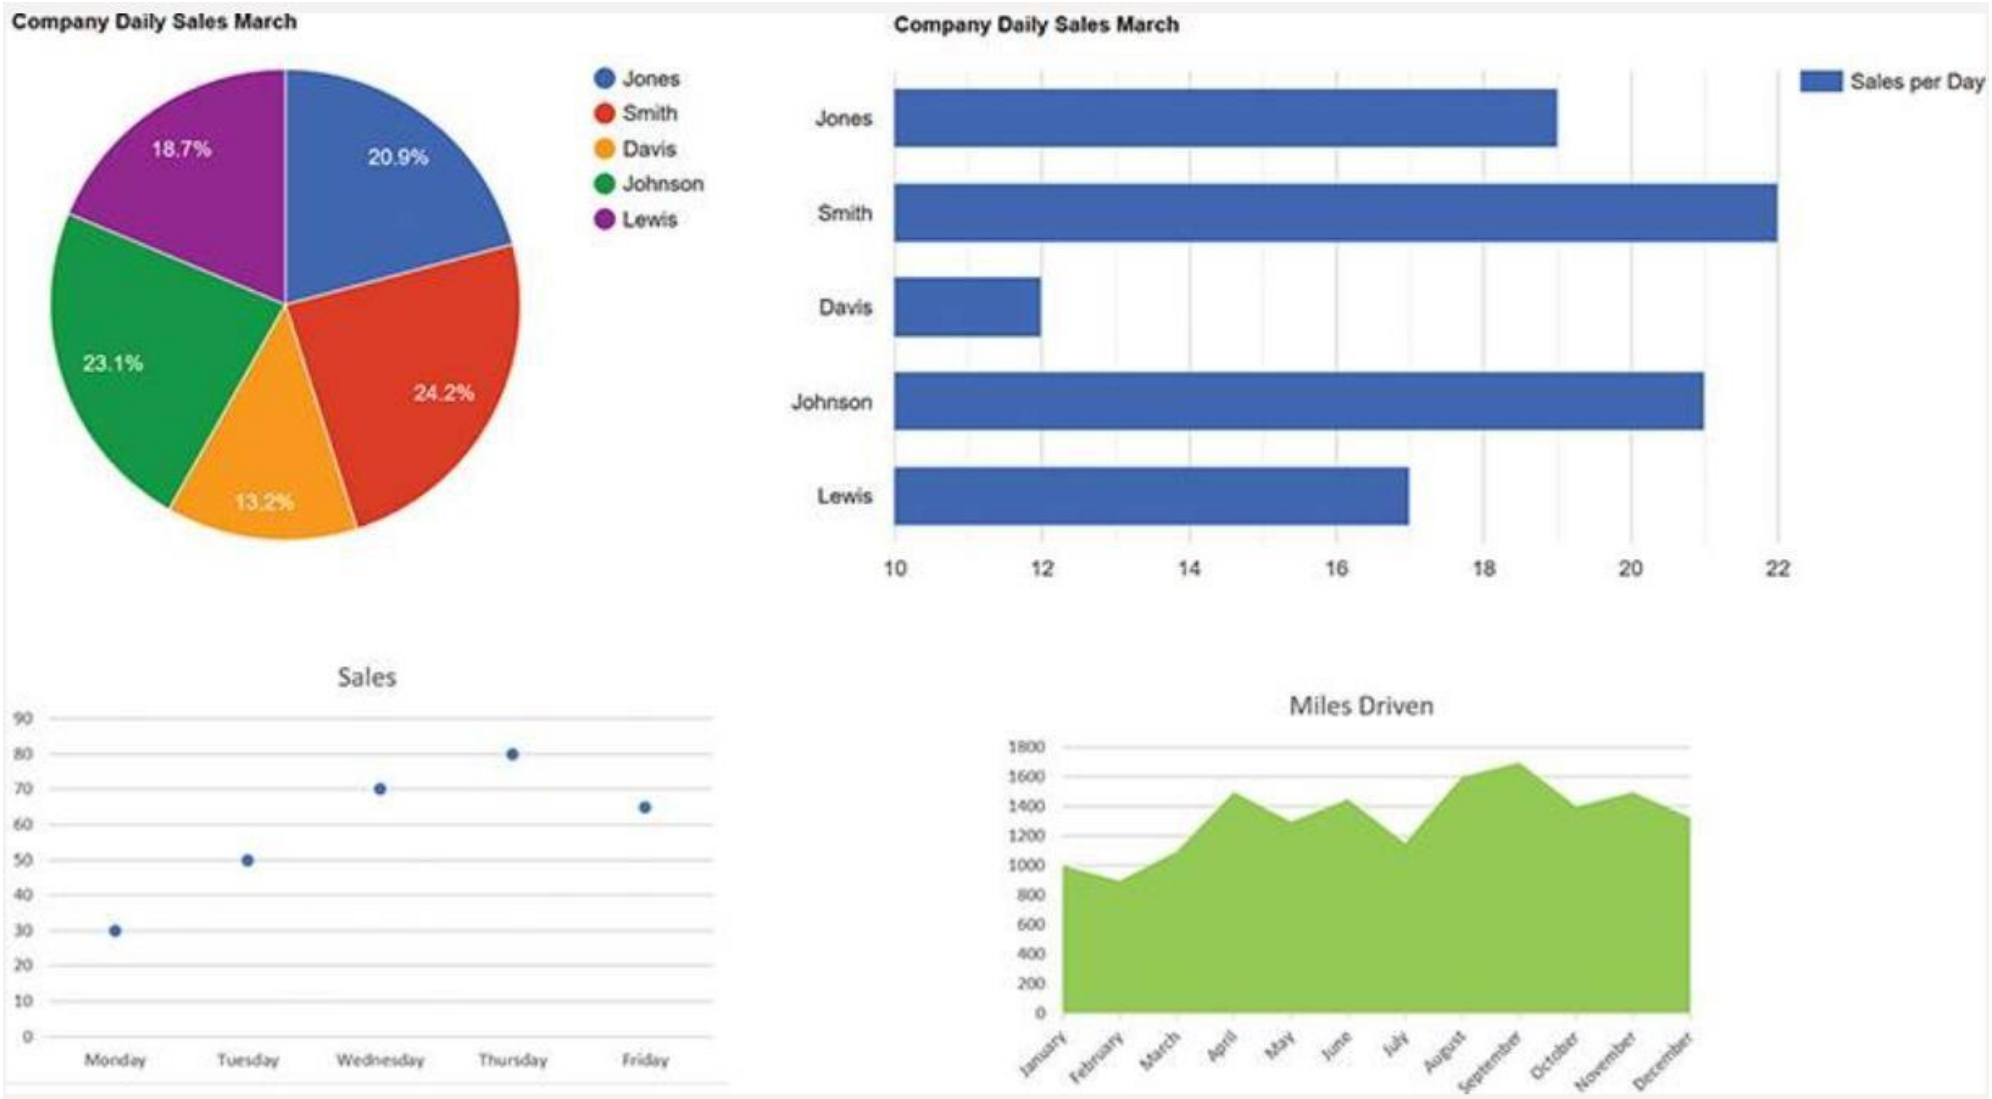








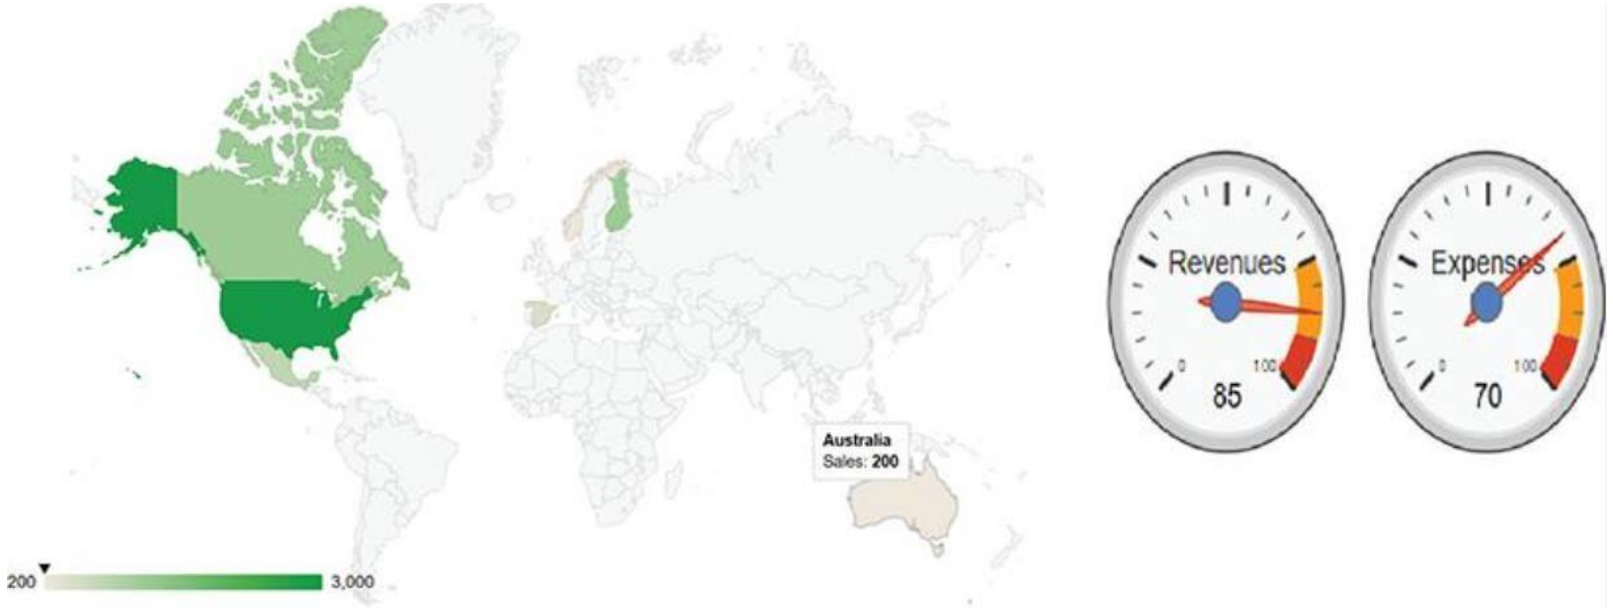
Data Visualization



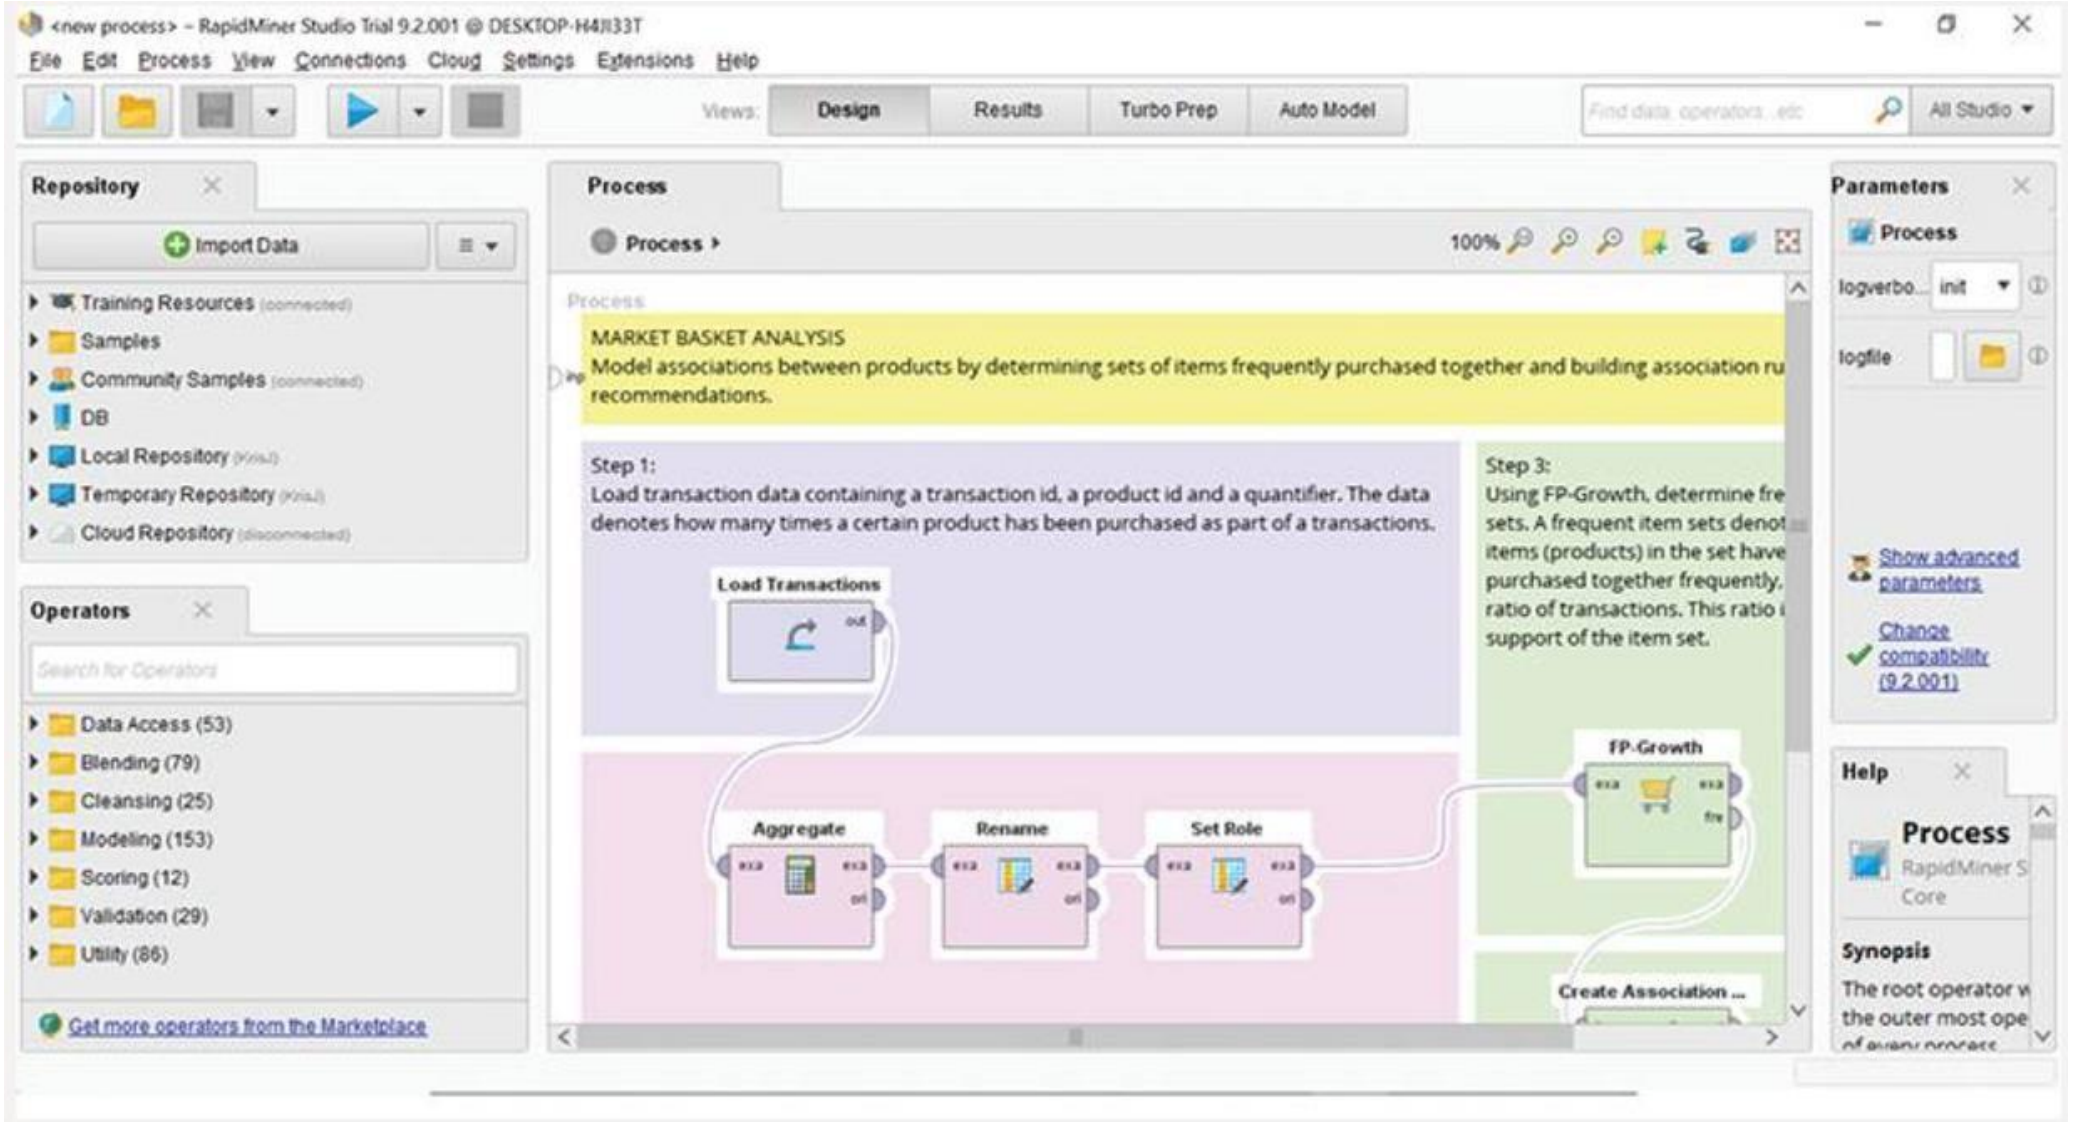
Data Visualization

- Gráficos de comparación temporales, que representan la evolución de uno o varios conjuntos de valores a lo largo del tiempo.
- Gráficos de comparación por categorías, que representan cómo se comparan dos o más categorías de valores.
- Gráficos de composición, que representan cómo uno o más valores se relacionan con un todo mayor.
- Gráficos de correlación, que representan cómo se relacionan dos o más variables.
- Gráficos de cuadros de mando, que representan indicadores clave de rendimiento que las empresas utilizan para hacer un seguimiento de las iniciativas.
- Gráficos de distribución, que representan la frecuencia de los valores dentro de un conjunto de datos.
- Geocharts, que representan cómo los valores de una ubicación se comparan con los valores en una ubicación diferente..

Data Visualization



Visual Programming



Business Intelligence

- La inteligencia empresarial es el uso de herramientas (minería de datos, aprendizaje automático y visualización) para convertir los datos en información y recomendaciones empresariales prácticas. La inteligencia empresarial a menudo utiliza cuadros de mando en los que los usuarios pueden hacer clic en los elementos para mostrar un mayor nivel de detalle..

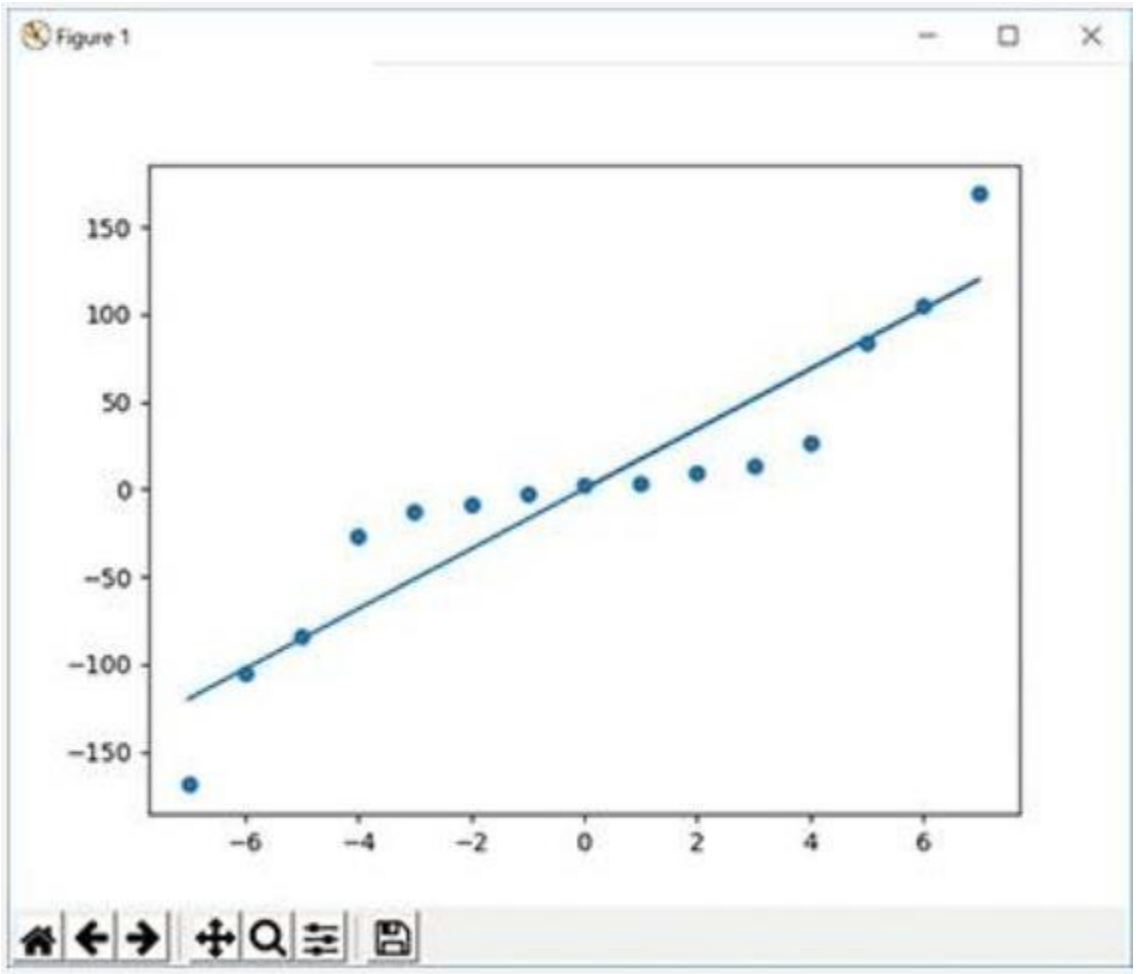
Data Cleansing and Wrangling

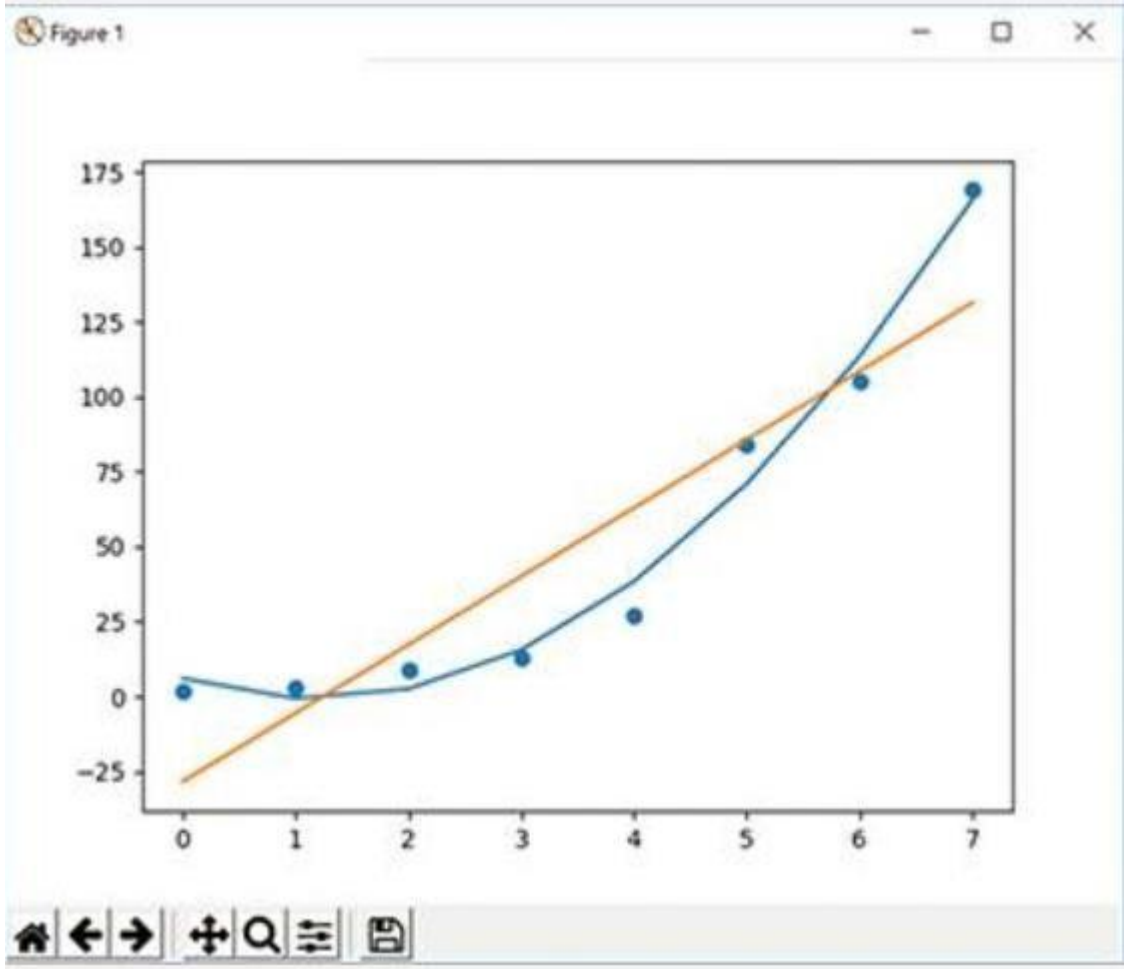
- Antes de que un analista de datos pueda iniciar el proceso de minería de datos, debe determinar la calidad del conjunto de datos e identificar cualquier anomalía, como datos ausentes o atípicos, que tendrá que resolver en. En el sentido más simple, la calidad de los datos es una medida de la idoneidad de los datos para su uso.

Data Clustering

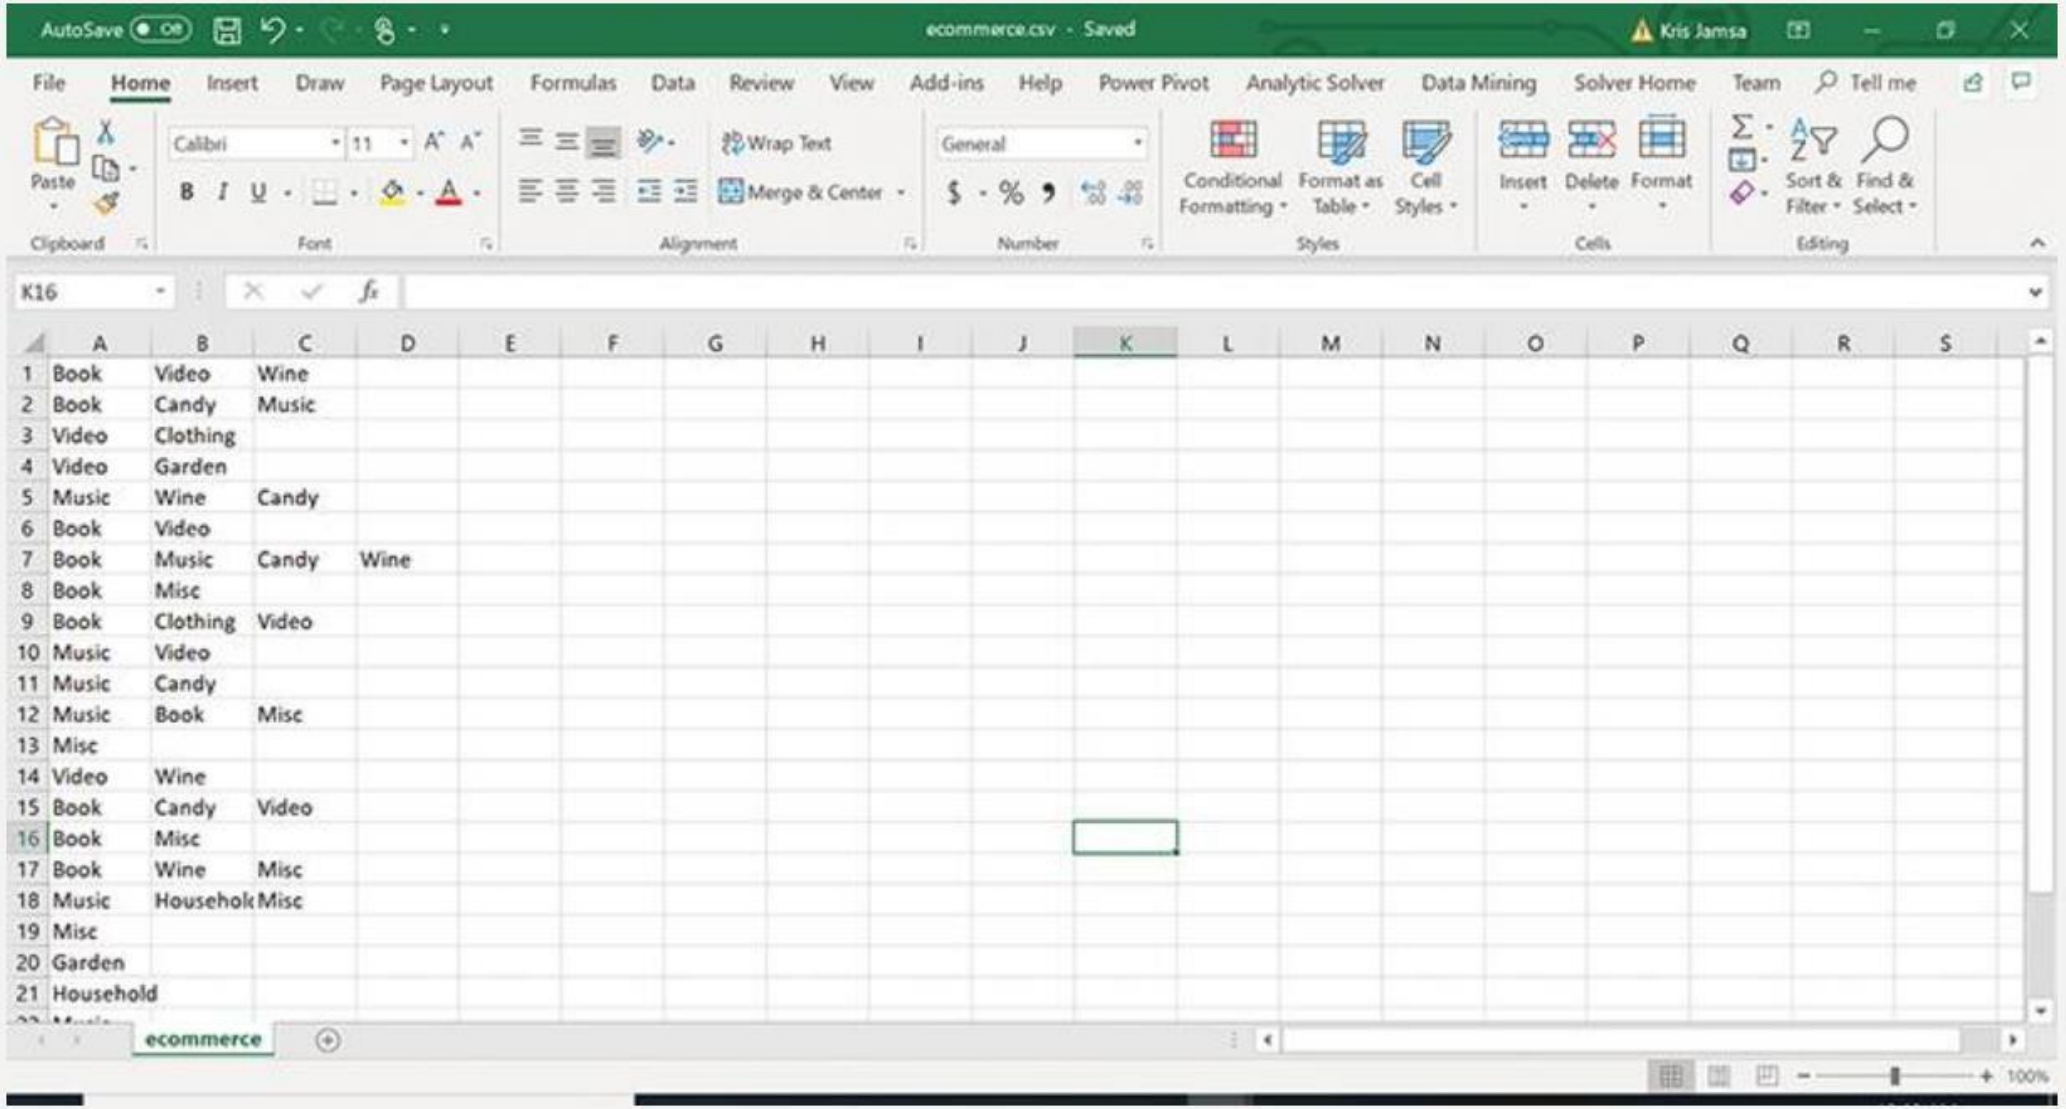


Predictive Analytics



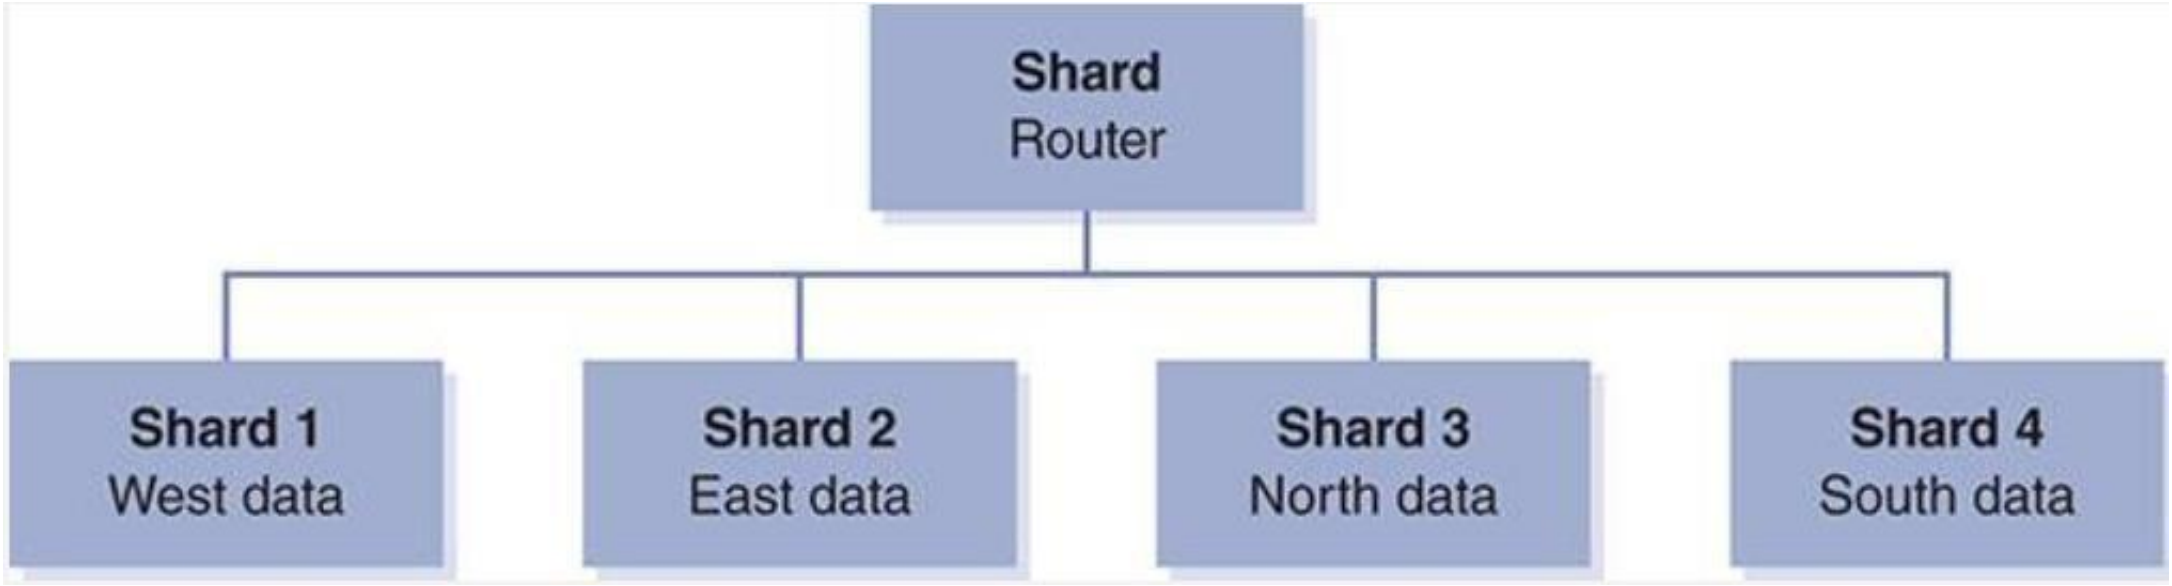


Data Association

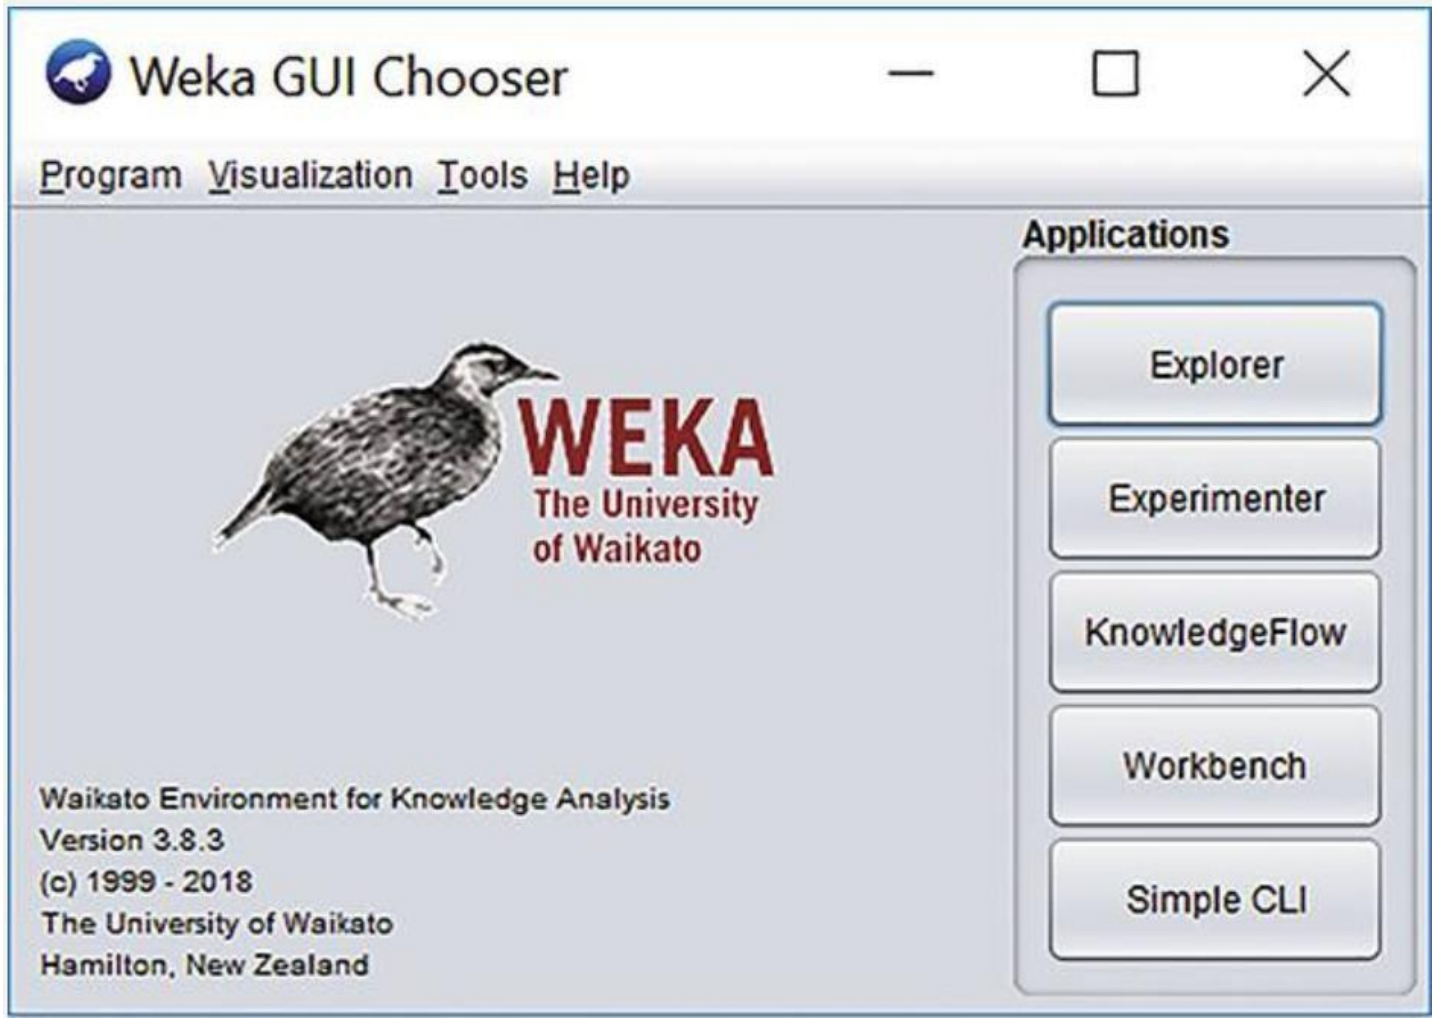


	A	B	C	D
1	Book	Video	Wine	
2	Book	Candy	Music	
3	Video	Clothing		
4	Video	Garden		
5	Music	Wine	Candy	
6	Book	Video		
7	Book	Music	Candy	Wine
8	Book	Misc		
9	Book	Clothing	Video	
10	Music	Video		
11	Music	Candy		
12	Music	Book	Misc	
13	Misc			
14	Video	Wine		
15	Book	Candy	Video	
16	Book	Misc		
17	Book	Wine	Misc	
18	Music	Household	Misc	
19	Misc			
20	Garden			
21	Household			

Big Data Mining and Analytics



Future of Data Mining and Analytics



Weka

- Limpieza de datos con Weka
- Visualización de datos con WekaI
- dentificación de variables de predicción con Weka
- Agrupación de datos con Weka
- Clasificación de datos con Weka
- Asociación de datos con Weka

Machine learning

- El aprendizaje automático es el uso de algoritmos de reconocimiento de patrones de datos para resolver problemas..

Machine learning

Operaciones de aprendizaje automático:

- Clasificación de datos.
- Agrupación de datos.
- Análisis predictivo.
- Asociación de datos.

Machine learning

- El aprendizaje automático es el uso de algoritmos de reconocimiento de patrones de datos para resolver problemas.
- Las soluciones de aprendizaje automático se clasifican en aprendizaje supervisado, no supervisado, reforzado y profundo.
- El aprendizaje supervisado es el uso de un algoritmo que utiliza datos etiquetados para producir un conjunto de datos de entrenamiento, a partir del cual el algoritmo puede aprender....

Machine learning

- Las soluciones de aprendizaje automático que utilizan el aprendizaje supervisado incluyen algoritmos de clasificación que determinan la categoría correcta de un elemento de datos, como un préstamo aprobado o desaprobado, un correo electrónico válido o spam, o un tumor maligno o benigno.
- El aprendizaje no supervisado no utiliza datos etiquetados ni un conjunto de datos de entrenamiento. Las soluciones de aprendizaje automático no supervisado identifican patrones de datos por descubrimiento, sin entrenamiento. Entre las soluciones de aprendizaje automático no supervisado más comunes se encuentran la agrupación y la asociación de datos.
- El aprendizaje reforzado es el uso de bucles de retroalimentación para recompensar las predicciones correctas y castigar los errores..

Machine learning

- El aprendizaje profundo es un proceso estructurado jerárquicamente que puede aprovechar las capas de aprendizaje automático, para las que la salida de una capa se convierte en la entrada de la siguiente.
- En el aprendizaje supervisado, uno de los primeros pasos que realizan la mayoría de los programas es dividir un conjunto de datos de origen en componentes de entrenamiento y de prueba, para lo cual el conjunto de datos de entrenamiento contiene normalmente entre el 70 % y el 80 % de los datos y el conjunto de datos de prueba contiene el resto.
- Un conjunto de datos de entrenamiento contiene datos de las variables independientes, que influyen en la variable dependiente, así como resultados correctos de la variable dependiente. Al examinar los valores de las variables independientes que conducen a resultados específicos (valores de las variables dependientes), el algoritmo de aprendizaje automático puede aprender.